

Fondements des probabilités

Table des matières

1	Espace de probabilité et vocabulaire probabiliste	5
1.1	Espace de probabilité	5
1.2	Propriétés élémentaires	7
1.3	lim inf et lim sup d'événements	8
1.4	Classe monotone	9
2	Variables aléatoires	11
2.1	Définition et propriétés	11
2.2	Loi d'une variable aléatoire	12
2.3	Fonction de répartition	14
2.4	Exemples de variables aléatoires	18
2.4.1	Variables discrètes	18
2.4.2	Théorème de Radon-Nikodym	20
2.4.3	Variables aléatoires à densité	21
3	Espérance d'une variable aléatoire	27
3.1	Définition et propriétés de l'espérance d'une variable aléatoire	27
3.2	Exemples de calcul d'espérance	31
3.2.1	Variables discrètes	31
3.2.2	Variables aléatoires à densité	32
3.2.3	Identification de la loi d'une variable aléatoire	33
3.3	Moments d'une variable aléatoire	34
3.4	Variance et covariance	36
4	Fonction caractéristique	41
4.1	Définition	41
4.2	Propriétés	42
4.3	Autres fonctionnelles caractérisant la loi	44
4.3.1	Fonction génératrice pour des variables aléatoires entières	44
4.3.2	Transformée de Laplace	45
5	Notion d'indépendance en probabilités	47
5.1	Définitions	47
5.2	Propriétés	49
5.3	Corrélation et indépendance	52
5.4	Événements asymptotiques	53
5.4.1	Tribu du futur et tribu asymptotique	53

5.4.2	Lemmes de Borel-Cantelli	55
5.5	Probabilité conditionnelle	56
5.6	Somme de variables aléatoires indépendantes	58
5.6.1	Convolution de mesures	59
5.6.2	Exemples	60
6	Convergence d'une suite de variables aléatoires	61
6.1	Convergence trajectorielle	61
6.1.1	Convergence presque sûre	61
6.1.2	Convergence dans L^p	63
6.1.3	Convergence en probabilité	64
6.1.4	Critères de convergence (de type Cauchy)	66
6.2	Convergence étroite et convergence en loi	67
6.2.1	Convergence étroite	67
6.3	Conclusion	70
7	Théorèmes limites	71
7.1	Loi des grands nombres	71
7.1.1	Version faible de la loi des grands nombres	71

Chapitre 1

Espace de probabilité et vocabulaire probabiliste

1.1 Espace de probabilité

L'espace fondamental est un triplet généralement noté $(\Omega, \mathfrak{F}, \mathbb{P})$. L'ensemble Ω est un ensemble non vide qui décrit toutes les réalisations possibles d'une expérience aléatoire. Un point $\omega \in \Omega$ est une réalisation de l'expérience.

Exemples : 1. Si on lance un dé,

$$\Omega = \{1, 2, 3, 4, 5, 6\} \quad (\text{ensemble fini})$$

2. On lance une pièce jusqu'à obtenir « face ». Dans ce cas,

$$\Omega = \{F, PF, PPF, PPPF, \dots\} \quad (\text{ensemble infini dénombrable})$$

3. On considère la durée de vie d'une ampoule. Dans ce cas,

$$\Omega = \mathbb{R}_+ \quad (\text{non dénombrable})$$

Au lieu de s'intéresser à toute l'expérience, on ne s'intéresse souvent qu'à un certain type de réalisations. Un évènement A est une combinaison de résultats possibles. On souhaite associer à un événement A un nombre $\mathbb{P}(A)$ qui permet de quantifier les chances de réalisation de A . Pour cela, on introduit la notion de tribu.

Soit Ω un ensemble. $\mathfrak{P}(\Omega)$ est l'ensemble des parties de Ω .

Définition 1.1

Une tribu \mathcal{F} sur Ω est un sous ensemble de $\mathfrak{P}(\Omega)$ tel que :

- $\Omega \in \mathcal{F}$;
- si $A \in \mathcal{F}$ alors $A^c \in \mathcal{F}$ (stabilité par passage au complémentaire) ;
- si $(A_i)_{i \geq 0}$ avec $A_i \in \mathcal{F}$ alors $\bigcup_{i \geq 0} A_i \in \mathcal{F}$ (stabilité par union dénombrable).

- Exemples :**
1. Tribu triviale $\mathcal{F} = \{\emptyset, \Omega\}$.
 2. Tribu grossière $\mathcal{F} = \mathfrak{P}(E)$.
 3. $\mathcal{F} = \{\emptyset, A, A^c, \Omega\}$ avec $A \in \mathfrak{P}(\Omega)$.

Proposition 1.2

Si \mathcal{F} est une tribu sur Ω , $\emptyset \in \mathcal{F}$, \mathcal{F} est stable par intersection finie ou dénombrable, union finie, par différence,...
Une intersection quelconque de tribus est une tribu.

Soit $A \subset \mathfrak{P}(\Omega)$, on définit $\sigma(A)$ comme la plus petite tribu contenant A :

$$\sigma(A) = \bigcap_{\substack{\mathcal{F} \text{ tribu} \\ A \in \mathcal{F}}} \mathcal{F}$$

$\sigma(A)$ est appelée tribu engendrée par A .

Exemple : Si Ω est topologique, la tribu borélienne $\mathcal{B}(\Omega)$ est la tribu engendrée par les ouverts.
 Si $\Omega = \mathbb{R}$, $\mathcal{B}(\mathbb{R})$ est engendrée par les intervalles de la forme $]s, t[$, avec $s, t \in \mathbb{R}$ et même $] -\infty, t[$, $t \in \mathbb{R}, \dots$

Si $\Omega = \mathbb{R}^d$, $\mathcal{B}(\mathbb{R}^d)$ est engendrée par les pavés $\prod_{i=1}^d]s_i, t_i[$.

Définition 1.3

On considère un espace mesurable (Ω, \mathcal{F}) . Une (mesure de) probabilité sur (Ω, \mathcal{F}) est une application $\mathbb{P} : \mathcal{F} \rightarrow [0, 1]$ telle que :

- $\mathbb{P}(\emptyset) = 0$;
- si $(A_i) \in \mathcal{F}$ avec $A_i \cap A_j = \emptyset \ \forall i \neq j$ alors

$$\mathbb{P} \left(\bigcup_{i \geq 0} A_i \right) = \sum_{i \geq 0} \mathbb{P}(A_i) \quad \sigma\text{-additivité};$$

- $\mathbb{P}(\Omega) = 1$.

Le triplet $(\Omega, \mathcal{F}, \mathbb{P})$ où (Ω, \mathcal{F}) est un espace mesurable et \mathbb{P} une probabilité est appelé espace de probabilité.

Exemples :

1. Mesure de Dirac. Soit $a \in \Omega$.

$$\delta_a(A) = \begin{cases} 1 & \text{si } a \in A \\ 0 & \text{sinon} \end{cases}$$

2. $([0, 1], \mathcal{B}([0, 1]), d\lambda)$ avec $d\lambda$ mesure de Lebesgue.
3. $(\mathbb{N}, \mathfrak{P}(\mathbb{N}))$. Une probabilité sur cet espace est de la forme

$$\mathbb{P} = \sum_{n \geq 0} p_n \delta_n$$

où $p_n \in [0, 1]$ tels que $\sum_{n \geq 0} p_n = 1$. Si $A \in \mathfrak{P}(\mathbb{N})$,

$$\mathbb{P}(A) = \sum_{n \geq 0} p_n \mathbf{1}_A(n).$$

1.2 Propriétés élémentaires

Ici \cup est interprété comme « ou », \cap est interprété comme « et ».

Proposition 1.4

Soit $(\Omega, \mathcal{F}, \mathbb{P})$ un espace de probabilité.

(i) Soient $A, B \in \mathcal{F}$. Si $A \cap B = \emptyset$, alors

$$\mathbb{P}(A \cup B) = \mathbb{P}(A) + \mathbb{P}(B)$$

(ii) Soit $A \in \mathcal{F}$.

$$\mathbb{P}(A^c) = 1 - \mathbb{P}(A).$$

(iii) Soient $A, B \in \mathcal{F}$. Si $A \subset B$, alors

$$\mathbb{P}(A) \subset \mathbb{P}(B)$$

(iv) Soient $A, B \in \mathcal{F}$.

$$\mathbb{P}(A \cup B) = \mathbb{P}(A) + \mathbb{P}(B) - \mathbb{P}(A \cap B)$$

(v) Soit $(A_i) \in \mathcal{F}$.

$$\mathbb{P}\left(\bigcup_{i \geq 0} A_i\right) \leq \sum_{i \geq 0} \mathbb{P}(A_i)$$

(vi) Soit $(A_i) \in \mathcal{F}$ une suite croissante d'événements : $A_i \subset A_{i+1}$. Alors

$$\mathbb{P}\left(\bigcup_{i \geq 0} A_i\right) = \lim_{i \rightarrow +\infty} \mathbb{P}(A_i) = \sup_{i \geq 0} \mathbb{P}(A_i).$$

(vii) Soit $(A_i) \in \mathcal{F}$ une suite décroissante d'événements : $A_{i+1} \subset A_i$. Alors

$$\mathbb{P}\left(\bigcap_{i \geq 0} A_i\right) = \lim_{i \rightarrow +\infty} \mathbb{P}(A_i) = \inf_{i \geq 0} \mathbb{P}(A_i).$$

▷ (ii) $\Omega = A \cup A^c$ et $\mathbb{P}(\Omega) = 1 = \mathbb{P}(A) + \mathbb{P}(A^c)$.

(iv) Soient $A, B \in \mathcal{F}$, $A \cup B = (A \setminus B) \sqcup (B \setminus A) \sqcup (A \cap B)$ Alors

$$\mathbb{P}(A \cup B) = \mathbb{P}(A \setminus B) + \mathbb{P}(A \cap B) + \mathbb{P}(B \setminus A)$$

Par ailleurs, $A = (A \setminus B) \sqcup (A \cap B)$ donc

$$\mathbb{P}(A) = \mathbb{P}(A \setminus B) + \mathbb{P}(A \cap B).$$

Ainsi,

$$\mathbb{P}(A \cup B) = \mathbb{P}(A) - \mathbb{P}(A \cap B) + \mathbb{P}(A \cap B) + \mathbb{P}(B) - \mathbb{P}(A \cap B).$$

□

Proposition 1.5 (*Formule de Poincaré*)

Soient $A_1, \dots, A_n \in \mathcal{F}$

$$\mathbb{P}\left(\bigcup_{i=1}^n A_i\right) = \sum_{i=1}^n \mathbb{P}(A_i) + \sum_{k=2}^n (-1)^{k+1} \sum_{1 \leq i_1 < i_2 < \dots < i_k \leq n} \mathbb{P}(A_{i_1} \cap A_{i_2} \cap \dots \cap A_{i_k}).$$

▷ Par récurrence (exercice). □

Pour trois événements $A, B, C \in \mathcal{F}$, on obtient

$$\mathbb{P}(A \cup B \cup C) = \mathbb{P}(A) + \mathbb{P}(B) + \mathbb{P}(C) - \mathbb{P}(A \cap B) - \mathbb{P}(A \cap C) - \mathbb{P}(B \cap C) + \mathbb{P}(A \cap B \cap C).$$

1.3 lim inf et lim sup d'événements

Soit $(\Omega, \mathcal{F}, \mathbb{P})$ un espace de probabilité. Soit $(A_n)_{n \geq 0}$ une suite d'événements.

Définition 1.6

On définit

$$\liminf_{n \rightarrow +\infty} A_n = \bigcup_{n \geq 0} \bigcap_{k > n} A_k$$

et

$$\limsup_{n \rightarrow +\infty} A_n = \bigcap_{n \geq 0} \bigcup_{k > n} A_k.$$

Rappel : Si (u_n) est une suite de réels,

$$\liminf_{n \rightarrow +\infty} u_n = \sup_n \inf_{k \geq n} u_k \leq \limsup_{n \rightarrow +\infty} u_n = \inf_n \sup_{k \geq n} u_k.$$

On remarque que

$$\liminf_n A_n \subset \limsup_n A_n$$

et

$$(\liminf A_n)^c = \limsup (A_n)^c.$$

Si $\omega \in \liminf A_n$, il existe $n \geq 0$ tel que $\forall k > n, \omega \in A_k$: « à partir d'un certain rang, ω est dans tous les A_k » ou « ω est dans tous les A_n sauf un nombre fini ».

Si $\omega \in \limsup A_n$, pour tout $n \geq 0$, il existe $k > n$ tel que $\omega \in A_k$: « ω est dans une infinité de A_n ».

Proposition 1.7

$$\mathbf{1}_{\liminf A_n} = \liminf \mathbf{1}_{A_n},$$

$$\mathbf{1}_{\limsup A_n} = \limsup \mathbf{1}_{A_n},$$

$$\mathbb{P}(\liminf A_n) \leq \liminf \mathbb{P}(A_n) \leq \limsup \mathbb{P}(A_n) \leq \mathbb{P}(\limsup A_n).$$

▷ cf. TD.

□

1.4 Classe monotone

Définition 1.8

Une famille \mathcal{M} de parties de Ω est appelée *classe monotone* si :

- $\Omega \in \mathcal{M}$;
- \mathcal{M} est stable par différence : si $A, B \in \mathcal{M}$ et $B \subset A$, alors $A \setminus B \in \mathcal{M}$;
- \mathcal{M} est stable par union croissante : si $(A_i) \in \mathcal{M}$ et $A_i \subset A_{i+1}$ alors $\bigcup_{i \geq 0} A_i \in \mathcal{M}$.

Soit $A \subset \mathfrak{P}(\Omega)$, on note $\mathcal{M}(A)$ la classe monotone engendrée par A :

$$\mathcal{M}(A) = \bigcap_{\substack{A \in \mathcal{M} \\ \mathcal{M} \text{ classe monotone}}} \mathcal{M}.$$

Remarques : – Une tribu est une classe monotone.

– Une classe monotone stable par intersection finie est une tribu.

Théorème 1.9 (*Théorème des classes montones*)

Soit $\mathcal{C} \subset \mathfrak{P}(\Omega)$ stable par intersection finie. Alors

$$\mathcal{M}(\mathcal{C}) = \sigma(\mathcal{C}).$$

Application : Théorème de Dynkin : Soient $\mathcal{C} \subset \mathfrak{P}(\Omega)$ stable par intersection finie, \mathbb{P}_1 et \mathbb{P}_2 deux probabilités sur Ω qui coïncident sur \mathcal{C} . Alors, elles coïncident sur $\sigma(\mathcal{C})$.

▷ Considérons $\mathcal{M} = \{A \in \mathfrak{P}(\Omega), \mathbb{P}_1(A) = \mathbb{P}_2(A)\}$. On a :

- $\Omega \in \mathcal{M}$ car $\mathbb{P}_1(\Omega) = 1 = \mathbb{P}_2(\Omega)$;
- si $A, B \in \mathcal{M}$ et $B \subset A$, $A \setminus B \in \mathcal{M}$ car

$$\mathbb{P}_1(A \setminus B) \underset{\mathbb{P}_1 \text{ proba}}{=} \mathbb{P}_1(A) - \mathbb{P}_1(B) \underset{A, B \in \mathcal{M}}{=} \mathbb{P}_2(A) - \mathbb{P}_2(B) \underset{\mathbb{P}_2 \text{ proba}}{=} \mathbb{P}_2(A \setminus B) ;$$

- si (A_i) est une suite croissante de \mathcal{M} ,

$$\mathbb{P}_1 \left(\bigcup_{i \geq 0} A_i \right) = \lim_{i \rightarrow +\infty} \mathbb{P}_1(A_i) = \lim_{i \rightarrow +\infty} \mathbb{P}_2(A_i) = \mathbb{P}_2 \left(\bigcup_{i \geq 0} A_i \right)$$

donc $\bigcup_{i \geq 0} A_i \in \mathcal{M}$.

Par conséquent, \mathcal{M} est une classe monotone. Comme $\mathcal{C} \subset \mathcal{M}$, on conclut par le théorème des classes monotones. □

Chapitre 2

Variables aléatoires

Exemple : On lance dix fois un dé à six faces. À chaque lancer, le joueur gagne 2 euros si le résultat est 5 ou 6, 1 euro si c'est un 4, rien si c'est un 3 et perd 1 euro si c'est un 2, 3 euros si c'est un 5.

$$\Omega = \{1, 2, 3, 4, 5, 6\}^{10}$$

$$\mathcal{F} = \mathfrak{P}(\Omega)$$

$$\forall \omega \in \Omega \quad \mathbb{P}(\{\omega\}) = \left(\frac{1}{6}\right)^{10}.$$

Pour le joueur, la description complète de l'expérience est inutile, il veut juste connaître son gain final. Le gain est une application de Ω à valeurs dans $\{-30, \dots, 20\}$. On parle de variable aléatoire.

2.1 Définition et propriétés

Soient (Ω, \mathcal{F}) et (E, \mathcal{E}) deux espaces mesurables et X une application de Ω dans E . On note, pour $A \in \mathcal{E}$,

$$\{X \in A\} = X^{-1}(A) = \{\omega \in \Omega, X(\omega) \in A\}.$$

Si A est un singleton, $A = \{a\}$, on fait l'abus de notation suivant :

$$\{X \in \{a\}\} = \{X = a\}.$$

Définition 2.1

On appelle variable aléatoire (v.a.) toute application mesurable X d'un espace de probabilité $(\Omega, \mathcal{F}, \mathbb{P})$ à valeurs dans un espace mesurable (E, \mathcal{E}) mesurable, c'est-à-dire $X^{-1}(\mathcal{E}) \subset \mathcal{F}$.

Si $(E, \mathcal{E}) = (\mathbb{R}, \mathcal{B}(\mathbb{R}))$ on parle variable aléatoire réelle.

Si $(E, \mathcal{E}) = (\mathbb{R}^d, \mathcal{B}(\mathbb{R}^d))$ on parle de vecteur aléatoire. On peut écrire $X = (X_1, \dots, X_d)$ avec $X_i : (\Omega, \mathcal{F}, \mathbb{P}) \rightarrow (\mathbb{R}, \mathcal{B}(\mathbb{R}))$ une variable aléatoire réelle. Dans ce cas, X_i s'appelle la i -ème marginale du vecteur X .

Si $(E, \mathcal{E}) = (\mathbb{N}, \mathfrak{P}(\mathbb{N}))$ on parle de variable aléatoire entière.

Exemple : Une fonction étagée est une fonction mesurable qui prend un nombre fini de valeurs :

$$X = \sum_{i=1}^n x_i \mathbf{1}_{A_i} \quad \text{avec } x_i \in E, A_i \in \mathcal{F}.$$

Rappel : toute variable aléatoire est limite simple de fonctions étagées et si la variable aléatoire est positive, la limite peut être choisie croissante.

Proposition 2.2

Si $\mathcal{E} = \sigma(\mathcal{C})$, X est une variable aléatoire si et seulement si $X^{-1}(\mathcal{C}) \subset \mathcal{F}$.

Conséquence : X est une variable aléatoire réelle si et seulement si $\{X \leq t\} \in \mathcal{F} \forall t \in \mathbb{R}$, car les intervalles $] -\infty, t]$, $t \in \mathbb{R}$, engendrent la tribu borélienne.

▷ \Rightarrow OK

\Leftarrow Supposons que $X^{-1}(\mathcal{C}) \subset \mathcal{F}$. On définit

$$\mathcal{A} = \{A \in \mathcal{E}, X^{-1}(A) \in \mathcal{F}\}.$$

– $\mathcal{C} \subset \mathcal{A}$.

– $X^{-1}(E) = \{\omega \in \Omega, X(\omega) \in E\} = \Omega \in \mathcal{F}$ donc $E \in \mathcal{A}$.

– Soit $A \in \mathcal{A}$

$$X^{-1}(A^c) = \{\omega \in \Omega, X(\omega) \notin A\} = \underbrace{(X^{-1}(A))^c}_{\in \mathcal{F}} \in \mathcal{F} \text{ (tribu)}$$

donc $A^c \in \mathcal{A}$.

– Soit $(A_i)_{i \geq 0}, A_i \in \mathcal{A}$.

$$X^{-1}\left(\bigcup_{i \geq 0} A_i\right) = \{\omega \in \Omega, X(\omega) \in \bigcup_{i \geq 0} A_i\} = \bigcup_{i \geq 0} X^{-1}(A_i) \in \mathcal{F}$$

donc $\bigcup_{i \geq 0} A_i \in \mathcal{A}$.

Ainsi, \mathcal{A} est une tribu qui contient \mathcal{C} , donc $\mathcal{A} = \mathcal{E} = \sigma(\mathcal{C})$. □

Rappel : Comme la mesurabilité est stable par composition, la somme, la différence, le quotient de variables aléatoires réelles est une variable aléatoire réelle. Si l'on considère une suite de variables aléatoires, alors l'inf, le sup, la liminf, limsup sont des variables aléatoires.

2.2 Loi d'une variable aléatoire

Définition 2.3

¹ Soit $X : (\Omega, \mathcal{F}, \mathbb{P}) \rightarrow (E, \mathcal{E})$ une variable aléatoire. On appelle loi de X , notée \mathbb{P}_X , la mesure

image de \mathbb{P} par l'application X : pour $A \in \mathcal{E}$,

$$\mathbb{P}_X(A) = \mathbb{P}(X \in A) = \mathbb{P}(\{\omega \in \Omega, X(\omega) \in A\})$$

Dans le cas d'un vecteur aléatoire $X = (X_1, \dots, X_d)$, la loi $\mathbb{P}_{(X_1, \dots, X_d)}$ est appelée loi jointe du vecteur X . Les lois des marginales X_1, \dots, X_d sont appelées lois marginales

- ▷ Montrons que \mathbb{P}_X est une mesure de probabilité.
- $\mathbb{P}_X(E) = \mathbb{P}(\Omega) = 1$.
 - Soit (A_i) une famille d'ensembles disjoints de \mathcal{E} .

$$\mathbb{P}_X \left(\bigcup_{i \geq 0} A_i \right) = \mathbb{P} \left(X \in \bigcup_{i \geq 0} A_i \right) = \mathbb{P} \left(\bigcup_{i \geq 0} \{X \in A_i\} \right)$$

De plus, si $i \neq j$ et $\omega \in \{X \in A_i\}$, $X(\omega) \in A_i$. Si $\omega \in \{X \in A_j\}$ alors $\omega \in A_i \cap A_j = \emptyset$ donc $\{X \in A_i\} \cap \{X \in A_j\} = \emptyset$. Ainsi,

$$\mathbb{P}_X \left(\bigcup_{i \geq 0} A_i \right) = \sum_{i \geq 0} \mathbb{P}(\{X \in A_i\}) = \sum_{i \geq 0} \mathbb{P}_X(A_i).$$

Ainsi, \mathbb{P}_X est bien une mesure de probabilité. □

Exemple : On lance deux fois un dé et on regarde le minimum des chiffres obtenus.

$$\Omega = \{1, 2, 3, 4, 5, 6\}^2 = E^2$$

$$\mathcal{F} = \mathfrak{P}(\Omega)$$

$$\mathbb{P}(\{\omega\}) = \frac{1}{36}$$

$$X : \begin{array}{ll} (\Omega, \mathcal{F}, \mathbb{P}) & \rightarrow (E, \mathfrak{P}(E)) \\ \omega = (\omega_1, \omega_2) & \mapsto \min(\omega_1, \omega_2) \end{array}$$

Loi de X :

i	1	2	3	4	5	6
$\mathbb{P}(X = i)$	$\frac{11}{36}$	$\frac{9}{36}$	$\frac{7}{36}$	$\frac{5}{36}$	$\frac{3}{36}$	$\frac{1}{36}$

$$X^{-1}(\{6\}) = \{6, 6\}$$

$$X^{-1}(\{5\}) = \{(5, 6), (5, 5), (6, 5)\}$$

Définition 2.4

On dit que deux variables aléatoires X et Y ont la même loi si $\mathbb{P}_X = \mathbb{P}_Y$. On note $X \stackrel{\mathcal{L}}{=} Y$.

⚠ Le cas $X : (\Omega_1, \mathcal{F}_1, \mathbb{P}_2) \rightarrow (E, \mathcal{E})$ et $Y : (\Omega_2, \mathcal{F}_2, \mathbb{P}_2) \rightarrow (E, \mathcal{E})$ et $\mathbb{P}_X = \mathbb{P}_Y$ est possible !

Propriété 2.5

Si $(X, Y) \in E^2$ est une couple de variables aléatoires de loi $\mathbb{P}_{(X, Y)}$ alors les lois marginales \mathbb{P}_X

et \mathbb{P}_Y de X et Y sont données par

$$\forall A \in \mathcal{E} \quad \mathbb{P}_X(A) = \mathbb{P}_{(X,Y)}(A \times E) \quad \mathbb{P}_Y(A) = \mathbb{P}_{(X,Y)}(E \times A)$$

Plus généralement, si on a un n -uplet (X_1, \dots, X_n) de variables aléatoires

$$\mathbb{P}_{X_i}(A) = \mathbb{P}_{(X_1, \dots, X_n)}(E^{i-1} \times A \times E^{n-i})$$

▷ $\{X \in A\} = \{(X, Y) \in A \times E\}$ □

Définition 2.6

Soit X une variable aléatoire. On appelle atome de X (ou de sa loi) tout point $x \in E$ tel que $\mathbb{P}(X = x) \neq 0$.

Définition 2.7

On appelle support d'une variable aléatoire $X : \Omega \rightarrow \mathbb{R}$ le plus petit ensemble fermé $S(X)$ de \mathbb{R} tel que $\mathbb{P}_X(S(X)) = 1$.

On considère maintenant des variables aléatoires réelles : $E = \mathbb{R}$.

2.3 Fonction de répartition

Rappel : Si \mathbb{P}_1 et \mathbb{P}_2 coïncident sur \mathcal{C} et \mathcal{C} est stable par intersection finie, alors $\mathbb{P}_1 = \mathbb{P}_2$ sur $\sigma(\mathcal{C})$.

Conséquence : Soient X, Y sont deux variables aléatoires à valeurs dans (E, \mathcal{E}) avec $\mathcal{E} = \sigma(\mathcal{C})$ et \mathcal{C} stable par intersection finie et μ est une probabilité sur (E, \mathcal{E}) .

(i) X suit la loi μ si et seulement si $\forall A \in \mathcal{C} \mathbb{P}_X(A) = \mu(A)$

(ii) $X \stackrel{\mathcal{L}}{=} Y$ si et seulement si $\forall A \in \mathcal{C}, \mathbb{P}(X \in A) = \mathbb{P}(Y \in A)$.

Définition 2.8

On appelle fonction de répartition d'une variable aléatoire réelle $X : (\Omega, \mathcal{F}, \mathbb{P}) \rightarrow (\mathbb{R}, \mathcal{B}(\mathbb{R}))$ la fonction

$$F_X : \begin{array}{ll} \mathbb{R} & \rightarrow [0, 1] \\ x & \mapsto \mathbb{P}(X \leq x) \end{array}$$

Proposition 2.9

La fonction de répartition caractérise la loi d'une variable aléatoire, c'est-à-dire, si X et Y sont deux variables aléatoires telles que $F_X = F_Y$ alors $X \stackrel{\mathcal{L}}{=} Y$.

▷ $\mathcal{C} = \{]-\infty, x], x \in \mathbb{R}\}$. $\mathcal{B}(\mathbb{R}) = \sigma(\mathcal{C})$ et \mathcal{C} est stable par intersection finie. □

Exemple : On reprend l'exemple précédent du dé jeté deux fois. On considère le minimum des chiffres obtenus.

On a :

$$\forall x < 1, F_X(x) = \mathbb{P}(X \leq x) = 0$$

$$\forall x \in [1, 2[, F_X(x) = \mathbb{P}(X = 1)$$

$$\forall x \in [2, 3[, F_X(x) = \mathbb{P}(X = 1 \text{ ou } X = 2) = \mathbb{P}(X = 1) + \mathbb{P}(X = 2)$$

etc.




FIGURE 2.1 – Fonction de répartition de la variable aléatoire X

Proposition 2.10

- (i) F_X est une fonction croissante.
- (ii) $\lim_{x \rightarrow -\infty} F_X(x) = 0$ et $\lim_{x \rightarrow +\infty} F_X(x) = 1$.
- (iii) F_X est continue à droite et admet une limite à gauche en tout point de \mathbb{R} .

$$F_X(x^-) = \lim_{\substack{y \rightarrow x \\ y < x}} F_X(y) = \mathbb{P}(X < x).$$

$$(iv) \mathbb{P}(X \in [a, b]) = F_X(b) - F_X(a^-).$$

(v) Si x n'est pas un atome de X alors F_X est continue en x . L'ensemble des points de discontinuité de F_X est l'ensemble des atomes de X .

▷ (i) Soient $x, y \in \mathbb{R}$, $x \leq y$. Alors

$$F_X(x) = \mathbb{P}_X([-\infty, x]) \leq \mathbb{P}_X([-\infty, y]) = F_X(y)$$

car la mesure de probabilité est croissante.

(ii) On a $\lim_{x \rightarrow -\infty} F_X(x) = \lim_{n \rightarrow +\infty} F_X(-n) = \lim_{n \rightarrow +\infty} \mathbb{P}_X([-\infty, -n])$. On pose $A_n =]-\infty, -n]$, alors $(A_n)_{n \geq 0}$ est décroissante. Par décroissance séquentielle,

$$\lim_{x \rightarrow -\infty} F_X(x) = \lim_{n \rightarrow +\infty} \mathbb{P}_X(A_n) = \mathbb{P}_X\left(\bigcap_{n \geq 0} A_n\right) = 0.$$

En $+\infty$, $\lim_{x \rightarrow +\infty} F_X(x) = \lim_{n \rightarrow +\infty} F_X(n)$ avec $F_X(n) = \mathbb{P}_X(]-\infty, n])$. On pose $B_n =]-\infty, n]$, alors $(B_n)_{n \geq 0}$ est une suite croissante donc

$$\lim_{x \rightarrow +\infty} F_X(x) = \lim_{n \rightarrow +\infty} \mathbb{P}_X(B_n) = \mathbb{P}_X\left(\bigcup_{n \geq 0} B_n\right) = \mathbb{P}_X(\mathbb{R}) = 1.$$

(iii) Soit $x \in \mathbb{R}$.

$$\lim_{\substack{y \rightarrow x \\ y > x}} F_X(y) = \lim_{n \rightarrow +\infty} F_X\left(x + \frac{1}{n}\right).$$

Soit $A_n = \{X \leq x + \frac{1}{n}\}$. $(A_n)_{n \geq 0}$ est une suite décroissante et $\bigcap_{n \geq 0} A_n = \{X \leq x\}$ donc

$$\lim_{\substack{y \rightarrow x \\ y > x}} F_X(y) = \mathbb{P}(X \leq x) = F_X(x)$$

et F_X est continue à droite.

Les limites existent car F_X est croissante. Soit $x \in \mathbb{R}$.

$$\lim_{\substack{y \rightarrow x \\ y < x}} F_X(y) = \lim_{n \rightarrow +\infty} F_X\left(x - \frac{1}{n}\right).$$

Soit $B_n = \{X \leq x - \frac{1}{n}\}$. $(B_n)_{n \geq 0}$ est une suite croissante et $\bigcup_{n \geq 0} B_n = \{X < x\}$ donc

$$\lim_{\substack{y \rightarrow x \\ y < x}} F_X(y) = \mathbb{P}(X < x).$$

(iv) On a

$$\mathbb{P}(X \in [a, b]) = \mathbb{P}(X \in]-\infty, b] \setminus]-\infty, a]) = \mathbb{P}(X \in]-\infty, b]) - \mathbb{P}(X \in]-\infty, a]) = F_X(b) - F_X(a^-).$$

(v) F_X est continue en x si et seulement si $F_X(x^-) = F_X(x) = F_X(x^+)$ ie. $\mathbb{P}(X < x) = \mathbb{P}(X \leq x)$ avec

$$\mathbb{P}(X \leq x) = \mathbb{P}(X < x \text{ ou } X = x) = \mathbb{P}(X < x) + \mathbb{P}(X = x).$$

Donc F_X est continue sur x si et seulement si x n'est pas un atome de X . \square

Proposition 2.11

La fonction de répartition admet au plus un nombre dénombrable de points de discontinuité. Par conséquent, une variable aléatoire réelle a au plus un nombre dénombrable d'atomes.

\triangleright Soit D_n l'ensemble des points de discontinuité avec un saut d'amplitude supérieure ou égale à $\frac{1}{n}$:

$$D_n = \left\{x \in \mathbb{R}, F_X(x) - F_X(x^-) \geq \frac{1}{n}\right\}.$$

Comme $F_X(x) \in [0, 1]$ pour tout $x \in \mathbb{R}$, alors $\#D_n \leq n$. De plus, l'ensemble des points de discontinuité de F_X est $\bigcup_{n \geq 1} D_n$ donc il est au plus dénombrable. \square

Théorème 2.12

Une fonction $F : \mathbb{R} \rightarrow [0, 1]$ croissante, continue à droite et admettant une limite à gauche en

tout point de \mathbb{R} telle que

$$\lim_{x \rightarrow -\infty} F_X(x) = 0 \quad \text{et} \quad \lim_{x \rightarrow +\infty} F_X(x) = 1$$

est la fonction de répartition d'une variable aléatoire X .

▷ On se place dans le cas particulier $(\Omega, \mathcal{F}, \mathbb{P}) = ([0, 1[, \mathcal{B}([0, 1[), \lambda)$. On note $X(\omega) = \inf\{t \in \mathbb{R}, F(t) \geq \omega\}$ (remarque : si F est bijective, alors $X(\omega) = F^{-1}(\omega)$). X est une variable aléatoire sur $([0, 1[, \mathcal{B}([0, 1[), \lambda)$. Montrons que $\{t \in \mathbb{R}, F(t) \geq \omega\} = [X(\omega), +\infty[$.

⊂ : Soit $t \in \mathbb{R}$ tel que $F(t) \geq \omega$. Comme $X(\omega)$ est l'inf, $t \in [X(\omega), +\infty[$.

⊃ : Soit $t \in \mathbb{R}$ tel que $t \geq X(\omega)$. F étant croissante, $F(t) \geq F(X(\omega)) \geq \omega$ d'où l'égalité.

De plus,

$$\begin{aligned} F_X(x) &= \mathbb{P}(X \leq x) = \mathbb{P}(\{\omega \in \Omega, X(\omega) \leq x\}) = \mathbb{P}(\{\omega \in \Omega, x \in [X(\omega), +\infty[\}) \\ &= \mathbb{P}(\{\omega \in \Omega, x \in \{t \in \mathbb{R}, F(t) \geq \omega\}\}) = \mathbb{P}(\{\omega \in \Omega, F(x) \geq \omega\}) \\ &= \lambda([0, F(x)] = F(x) \end{aligned}$$

□

Définition 2.13

Soit $X = (X_1, \dots, X_d)$ un vecteur aléatoire de \mathbb{R}^d . On appelle fonction de répartition de X la fonction définie sur \mathbb{R}^d par

$$F_X(x) = F_X(x_1, \dots, x_d) = \mathbb{P}(X_1 \leq x_1, X_2 \leq x_2, \dots, X_d \leq x_d).$$

La fonction de répartition de X_i est

$$F_{X_i}(x_i) = \lim_{\substack{x_j \rightarrow +\infty \\ j \neq i}} F_X(x_1, \dots, x_d)$$

Remarque : La loi d'un vecteur aléatoire détermine la loi des marginales. Mais, de la loi des marginales on ne peut pas déduire la loi des vecteurs aléatoires.

Exemple : Soit (X, Y) un vecteur de loi

$$\mathbb{P}_{(X,Y)} = \frac{1}{6}\delta_{(0,0)} + \frac{1}{3}\delta_{(0,1)} + \frac{1}{12}\delta_{(1,0)} + \frac{5}{12}\delta_{(1,1)}$$

La loi de X est

$$\mathbb{P}_X = \frac{1}{2}\delta_0 + \frac{1}{2}\delta_1$$

et celle de Y est

$$\mathbb{P}_Y = \frac{1}{4}\delta_0 + \frac{3}{4}\delta_1.$$

Soit (U, V) des vecteurs aléatoires de loi

$$\mathbb{P}_{(U,V)} = \frac{1}{4}\delta_{(0,0)} + \frac{1}{4}\delta_{(0,1)} + \frac{1}{2}\delta_{(1,1)}.$$

Alors $\mathbb{P}_U = \mathbb{P}_X$ et $\mathbb{P}_Y = \mathbb{P}_V$ mais $\mathbb{P}_{(X,Y)} \neq \mathbb{P}_{(U,V)}$.

2.4 Exemples de variables aléatoires

2.4.1 Variables discrètes

Définition 2.14

Une variable aléatoire $X : (\Omega, \mathcal{F}, \mathbb{P}) \rightarrow (\mathbb{R}, \mathcal{B}(\mathbb{R}))$ est dite discrète si elle prend un nombre au plus dénombrable de valeurs.

Soit A l'ensemble des atomes d'une variable aléatoire discrète X . A est au plus dénombrable et $\mathbb{P}_X(A) = 1$.

Si X est une variable aléatoire discrète alors sa loi est la somme pondérée des mesures de Dirac en ses atomes :

$$\mathbb{P}_X = \sum_{x \in A} \mathbb{P}(X = x) \delta_x(A).$$

▷ $A = \bigcup_{x \in A} \{x\}$. Soit $B \in \mathcal{B}(\mathbb{R})$. Alors

$$\begin{aligned} \mathbb{P}_X(B) &= \mathbb{P}(X \in B) = \mathbb{P}\left(X \in B \cap \bigcup_{x \in A} \{x\}\right) \\ &= \mathbb{P}\left(X \in \bigcup_{x \in A} B \cap \{x\}\right) = \sum_{x \in A} \underbrace{\mathbb{P}(B \cap \{x\})}_{\mathbb{P}(X=x \text{ et } x \in B)} = \sum_{x \in A} \mathbb{P}(X = x) \\ &= \sum_{x \in A} \mathbb{P}(X = x) \mathbf{1}_{x \in B} = \sum_{x \in A} \mathbb{P}(X = x) \delta_x(B) \end{aligned}$$

□

Proposition 2.15

Soit X une variable aléatoire discrète et A l'ensemble de ses atomes $A = \{x_i, i \in I\}$ ordonné ($x_i < x_{i+1}$). Alors, la fonction de répartition F_X de X est croissante et constante sur chaque intervalle $[x_i, x_{i+1}[$. Le saut est égal à $p_i = \mathbb{P}(X = x_i)$.

▷ Soient $s, t \in [x_i, x_{i+1}[$, $s < t$.

$$F_X(t) - F_X(s) = \mathbb{P}(X \in]s, t]) = \sum_{\{k, s < x_k \leq t\}} p_i = 0.$$

□

Exemples : (i) X variable aléatoire constante : $\forall \omega \in \Omega, X(\omega) = c$. Alors $\mathbb{P}_X = \delta_c$ car $\mathbb{P}_X(A) = \mathbb{P}(X \in A) = \mathbb{P}(c \in A) = \mathbf{1}_{c \in A}$.

(ii) Si X est à valeurs dans un ensemble fini $\{x_1, \dots, x_n\}$ alors $\mathbb{P}_X = \sum_{i=1}^n p_i \delta_{x_i}$ avec $p_i = \mathbb{P}(X = x_i) \in [0, 1]$.

(iii) Si tous les atomes ont la même probabilité de se réaliser on parle de loi équirépartie.

$$\mathbb{P}_X = \sum_{i=1}^n \frac{1}{n} \delta_{x_i}$$

exemple : dé non truqué : $\mathbb{P}_X = \sum_{i=1}^6 \frac{1}{6} \delta_i$.

Loi équirépartie sur \mathbb{N} ? $\sum_{n \in \mathbb{N}} p = 1$: impossible.

(iv) $A \in \mathcal{F}$, $X(\omega) = \mathbf{1}_A(\omega)$. X est à valeurs dans $\{0, 1\}$

$$\mathbb{P}(X = 0) = \mathbb{P}_X(\mathbf{1}_A = 0) = \mathbb{P}(A^c) = 1 - \mathbb{P}(A)$$

et $\mathbb{P}(X = 1) = \mathbb{P}(A)$. Alors, $\mathbb{P}_X = \mathbb{P}(A)\delta_1 + (1 - \mathbb{P}(A))\delta_0$ est appelée loi de Bernoulli.

(v) Loi binomiale : on compte le nombre de succès lorsqu'on réalise n expériences de manière indépendante. Par exemple : lancer d'une pièce n fois, et on compte le nombre de face. X est à valeurs dans $\{0, \dots, n\}$. On note p la probabilité que la pièce tombe sur face. Alors

$$\mathbb{P}(X = k) = \mathbb{P}(k \text{ fois face et } (n - k) \text{ fois pile}) = \binom{n}{k} p^k (1 - p)^{n-k}$$

où $\binom{n}{k} = \frac{n!}{k!(n-k)!}$.

Remarque : $1 = \mathbb{P}_X(\{0, \dots, n\}) = \sum_{k=0}^n \mathbb{P}(X = k) = \sum_{k=0}^n \binom{n}{k} p^k (1 - p)^{n-k} = (p + 1 - p)^n = 1$
ok.

Formule du binôme :

$$\sum_{k=0}^n \binom{n}{k} a^k b^{n-k} = (a + b)^n.$$

Triangle de Pascal :

$$\binom{n}{k} = \binom{n-1}{k-1} + \binom{n-1}{k}.$$

(v) Loi géométrique : loi du premier succès. Par exemple, X est le nombre de lancers nécessaires pour avoir un "pile". X est à valeurs dans \mathbb{N}^* . En notant $p \in]0, 1[$ la probabilité d'un succès, on a :

$$\forall k \in \mathbb{N}^*, \quad \mathbb{P}(X = k) = \mathbb{P}((k-1) \text{ faces puis pile}) = (1-p)^{k-1} p.$$

Vérification : $\mathbb{P}(X = k) \in [0, 1]$ et $\sum_{k=1}^{+\infty} \mathbb{P}(X = k) = p \sum_{k=1}^{+\infty} (1-p)^{k-1} = \frac{p}{1 - (1-p)} = 1$.

Ici,

$$\mathbb{P}_X = \sum_{k=1}^{+\infty} (1-p)^{k-1} p \delta_k.$$

(vi) Loi de Poisson sur \mathbb{N} .

$$\forall k \in \mathbb{N}, \quad \mathbb{P}(X = k) = \frac{\lambda^k}{k!} e^{-\lambda}$$

où λ est un paramètre strictement positif.

Remarques : 1. Soit X une variable aléatoire discrète à valeurs dans $\mathcal{X} = \{x_i, i \in I\}$ avec $\mathbb{P}(X = x_i) = p_i$. Soit $g : \mathbb{R} \rightarrow \mathbb{R}$ une application mesurable. Alors, $Y = g(X)$ est une variable aléatoire discrète à valeurs dans $\{y_j, j \in J\} = \{g(x_i), i \in I\} = g(\mathcal{X})$. De plus,

$$\mathbb{P}(Y = y_j) = \sum_{\substack{i \in I \\ g(x_i) = y_j}} p_i.$$

▷ Y est bien une variable aléatoire à valeurs dans $g(\mathcal{X})$. De plus,

$$\mathbb{P}(Y = y_j) = \mathbb{P}(g(X) = y_j) = \mathbb{P}(g \circ X = y_j) = \mathbb{P}(X \in g^{-1}(\{y_j\})) = \sum_{\substack{i \in I \\ g(x_i) = y_j}} p_i$$

□

2. Soit (X, Y) un vecteur aléatoire discret à valeurs dans $\{(x_i, y_j), (i, j) \in I \times J\}$. Alors, les lois des marginales sont

$$\mathbb{P}_X(x_i) = \sum_{j \in J} \mathbb{P}((X, Y) = (x_i, y_j)) \quad \text{et} \quad \mathbb{P}_Y(y_j) = \sum_{i \in I} \mathbb{P}((X, Y) = (x_i, y_j)).$$

Exemple : on lance deux dés. X est le nombre de chiffres pairs. Y est le maximum des deux chiffres. Quelle est la loi de (X, Y) ?

(X, Y) est à valeurs dans $\{0, 1, 2\} \times \{1, \dots, 6\}$.

$X \backslash Y$	1	2	3	4	5	6	Loi de X
0	$\frac{1}{36}$	0	$\frac{3}{36}$	0	$\frac{5}{36}$	0	$\frac{1}{4}$
1	0	$\frac{2}{36}$	$\frac{2}{36}$	$\frac{4}{36}$	$\frac{4}{36}$	$\frac{6}{36}$	$\frac{1}{2}$
2	0	$\frac{1}{36}$	0	$\frac{3}{36}$	0	$\frac{5}{36}$	$\frac{1}{4}$
Loi de Y	$\frac{1}{36}$	$\frac{1}{12}$	$\frac{5}{36}$	$\frac{7}{36}$	$\frac{9}{36}$	$\frac{11}{36}$	(1)

2.4.2 Théorème de Radon-Nikodym

Définition 2.16

Soient μ et ν deux mesures sur (Ω, \mathcal{F}) . On dit que μ est absolument continue par rapport à ν ($\mu \ll \nu$) si

$$\forall A \in \mathcal{F}, \quad \nu(A) = 0 \implies \mu(A) = 0.$$

Théorème 2.17

Soient μ et ν deux mesures σ -finies. Si $\mu \ll \nu$ alors il existe $f : (\Omega, \mathcal{F}) \rightarrow \mathbb{R}$ mesurable telle que

$$\forall A \in \mathcal{F}, \quad \mu(A) = \int_A f d\nu$$

f est appelée densité de μ par rapport à ν , notée $f = \frac{d\mu}{d\nu}$. De plus, si μ est une mesure finie, alors $f \in L^1(\nu)$.

Remarque : (i) Dans ce cas, $\int g d\mu = \int g f d\nu$.

(ii) Si les mesures μ et ν sont positives alors f est positive.

Conséquence : Si μ est une mesure de probabilité et ν une mesure positive, si $\mu \ll \nu$ alors f est positive et

$$\int_{\Omega} f d\nu = 1.$$

Exemples : – Prenons ν la mesure de comptage sur \mathbb{N} :

$$\nu = \sum_{k \geq 0} \delta_k$$

et μ la loi de Bernoulli :

$$\mu = p\delta_1 + (1-p)\delta_0$$

Soit $A \in \mathbb{P}(\mathbb{N})$ tel que $\nu(A) = 0$. Alors $A = \mu(A)$ et donc $\mu(A) = 0$. Ainsi, $\mu \ll \nu$.

$$f(k) = \begin{cases} 1-p & \text{si } k = 0 \\ p & \text{si } k = 1 \\ 0 & \text{si } k \geq 2. \end{cases}$$

– Si $\nu = \lambda$ la mesure de Lebesgue. Aucune loi discrète est absolument continue par rapport à λ car $\lambda(\{x\}) = 0$ et $\mu(\{x\}) \neq 0$ pour x bien choisi.

– Soit X une variable aléatoire positive telle que sa loi vérifie :

$$\forall t, s \geq 0, \quad \mathbb{P}(X > t+s) = \mathbb{P}(X > t)\mathbb{P}(X > s).$$

Alors,

$$\mathbb{P}(X > t) = e^{-\alpha t} \quad \alpha > 0$$

$$\mathbb{P}(X \leq t) = \mathbb{P}(X \in [0, t]) = 1 - e^{-\alpha t} = \int_0^t \alpha e^{-\alpha s} ds.$$

Par conséquent, la loi de X est absolument continue par rapport à λ de densité

$$f(t) = \alpha e^{-\alpha t} \mathbf{1}_{t \geq 0}$$

(Loi exponentielle)

2.4.3 Variables aléatoires à densité

Définition 2.18

X est une variable aléatoire à densité si $\mathbb{P}_X \ll \lambda$. On note f sa densité.

$$\mathbb{P}(X \in A) = \int_A f(x) dx$$

f est positive et

$$\int_{\mathbb{R}} f(x) dx = 1.$$

On note alors la loi de $X : f(x)dx$.

Exemples : – Loi exponentielle de densité

$$f(x) = \alpha e^{-\alpha x} \mathbf{1}_{x \geq 0} \quad \alpha > 0.$$

– Loi uniforme sur $[a, b]$ de densité

$$f(x) = \frac{1}{b-a} \mathbf{1}_{[a,b]}(x)$$

– Loi normale (ou gaussienne) de densité

$$f(x) = \frac{1}{\sqrt{2\pi}} e^{-\frac{x^2}{2}}.$$

Rappel :

$$\begin{aligned} \left(\int_{\mathbb{R}} e^{-\frac{x^2}{2}} dx \right)^2 &= \int_{\mathbb{R}} e^{-\frac{x^2}{2}} dx \int_{\mathbb{R}} e^{-\frac{y^2}{2}} dy \stackrel{\text{Fubini-Tonelli}}{=} \int_{\mathbb{R} \times \mathbb{R}} e^{-\frac{x^2+y^2}{2}} dx dy \\ &= \int_0^{+\infty} \int_0^{2\pi} e^{-\frac{\rho^2}{2}} \rho d\rho d\theta = 2\pi \left[-e^{-\frac{\rho^2}{2}} \right]_0^{+\infty} = 2\pi \end{aligned}$$

Généralisation : loi gaussienne de moyenne m et de variance σ^2 :

$$f(x) = \frac{1}{\sqrt{2\pi}} e^{-\frac{(x-m)^2}{2\sigma^2}}.$$

Proposition 2.19

Soit X une variable à densité f . Alors sa fonction de répartition F_X vérifie :

(i) $\forall x \in \mathbb{R}, \quad F_X(x) = \int_{-\infty}^x f(t) dt.$

(ii) F_X est continue sur \mathbb{R} .

(iii) Si f est continue en x_0 , alors F_X est dérivable en x_0 et $F'_X(x_0) = f(x_0)$.

▷ (ii) F_X est discontinue en les atomes de X . Soit x un atome.

$$0 < \mathbb{P}(X = x) = \int_{\{x\}} f(t) dt = 0$$

ce qui est absurde donc si X est à densité alors X n'a pas d'atomes et donc F_X est continue sur \mathbb{R} .

(iii) f est continue en x_0 donc

$$\forall \varepsilon > 0, \exists \delta > 0, \forall t \in]x_0 - \delta, x_0 + \delta[, \quad |f(t) - f(x_0)| < \varepsilon.$$

Soit $\varepsilon > 0$ et δ comme ci-dessus. Soit $h \in \mathbb{R}$ tel que $0 < |h| < \delta$.

$$F_X(x_0 + h) - F_X(x_0) = \int_{x_0}^{x_0+h} f(t) dt$$

donc

$$|F_X(x_0 + h) - F_X(x_0) - hf(x_0)| = \left| \int_{x_0}^{x_0+h} (f(t) - f(x_0)) dt \right| \leq \left| \int_{x_0}^{x_0+h} |f(t) - f(x_0)| dt \right| \leq \varepsilon |h|.$$

Ainsi, F_X est dérivable en x_0 et $F'_X(x_0) = f(x_0)$. □

△ X variable aléatoire de fonction de répartition continue \nrightarrow X à densité.

Exemple de fonction croissante $[0, 1] \rightarrow [0, 1]$ continue : l'escalier de Cantor.

$f_0(x) = x$ pour $x \in [0, 1]$.

$f_1(x)$ fonction affine par morceaux telle que $f_1\left(\left[\frac{1}{3}, \frac{2}{3}\right]\right) = \left\{\frac{1}{2}\right\}$, $f_1(0) = 0$ et $f_1(1) = 1$.

Passage de f_n à f_{n+1} : sur chaque intervalle $[u, v]$ où f_n n'est pas constante, on remplace f_n par

la fonction affine par morceaux qui vaut $\frac{f_n(u) + f_n(v)}{2}$ sur $\left[\frac{2u}{3} + \frac{v}{3}, \frac{2v}{3} + \frac{u}{3}\right]$.

On remarque que

$$|f_{n+1}(x) - f_n(x)| \leq 2^{-n} \quad x \in [0, 1]$$

donc $\sum_{n \geq 0} (f_{n+1} - f_n)$ converge uniformément. Ainsi, la suite (f_n) converge uniformément donc

$f = \lim_{n \rightarrow \infty} f_n$ est croissante continue telle que $f(0) = 0$, $f(1) = 1$ et f est constante sur K^c où K est l'ensemble de Cantor (compact de $[0, 1]$, d'intérieur vide, de mesure de Lebesgue nulle). f est dérivable presque partout de dérivée nulle. Si X était à densité, sa densité serait nulle ce qui est absurde.

Remarque : Si X est à densité, alors F_X est absolument continue.

Proposition 2.20

Si X est une variable aléatoire ayant une fonction de répartition F_X de la forme

$$F_X(x) = \int_{-\infty}^x f(t) dt$$

où f est mesurable positive, alors X est une variable aléatoire de densité f .

▷ f est mesurable positive donc

$$\int_{\mathbb{R}} f(t) dt = \lim_{x \rightarrow +\infty} F_X(x) = 1$$

donc f est une densité.

Soit μ la mesure définie par

$$\forall A \in \mathcal{B}(\mathbb{R}), \quad \mu(A) = \int_A f(x) dx.$$

On a

$$\forall x \in \mathbb{R}, \quad \mu([-\infty, x]) = \mathbb{P}_X([-\infty, x]).$$

Comme l'ensemble $\{[-\infty, x], x \in \mathbb{R}\}$ est stable par intersection, $\mu = \mathbb{P}_X$ sur $\sigma(\{[-\infty, x], x \in \mathbb{R}\}) = \mathcal{B}(\mathbb{R})$. □

Cas d'un vecteur aléatoire à densité

Définition 2.21

Soit (X_1, \dots, X_d) un vecteur aléatoire sur $(\mathbb{R}^d, \mathcal{B}(\mathbb{R}^d))$. On dit que (X_1, \dots, X_d) est à densité

s'il existe une fonction $f : \mathbb{R}^d \rightarrow \mathbb{R}$ mesurable positive telle que

$$\forall A \in \mathcal{B}(\mathbb{R}^d), \quad \mathbb{P}((X_1, \dots, X_d) \in A) = \int_A f(t) dt = \int_A f(t_1, \dots, t_d) dt_1 \dots dt_d$$

et

$$\int_{\mathbb{R}^d} f(t) dt = 1.$$

Proposition 2.22

Si (X, Y) est un vecteur aléatoire de densité $f_{(X,Y)}$ alors les marginales sont à densité :

$$f_X(x) = \int_{\mathbb{R}} f_{(X,Y)}(x, y) dy \quad f_Y(y) = \int_{\mathbb{R}} f_{(X,Y)}(x, y) dx.$$

$$\triangleright \quad \mathbb{P}_X(A) = \mathbb{P}(X \in A, Y \in \mathbb{R}) = \int_{A \times \mathbb{R}} f_{(X,Y)}(x, y) dx dy \stackrel{\text{Fubini-Tonelli}}{=} \int_A \left(\int_{\mathbb{R}} f_{(X,Y)}(x, y) dy \right) dx. \quad \square$$

Proposition 2.23

Soit X une variable aléatoire à densité f . On note

$$S_f = \overline{\left\{ x \in \mathbb{R}, \forall V(x) \text{ voisinage de } x, \int_{V(x)} f(t) dt > 0 \right\}}$$

On a

$$S(X) = S_f.$$

\triangleright — $S(X) \subset S_f$: S_f^c est un ouvert. Pour chaque $x \in S_f^c$ il existe un voisinage $V(x)$ de x tel que $\int_{V(x)} f(t) dt = 0$. S_f^c est un ouvert de \mathbb{R} donc il peut s'écrire sous la forme

$$S_f^c = \bigcup_{i \in I}]a_i, b_i[, \quad a_i, b_i \in \overline{\mathbb{R}}$$

avec I un ensemble dénombrable. Pour tout $i \in I$, $]a_i, b_i[\subset \bigcup_{x \in]a_i, b_i[\cap \mathbb{Q}} V(x)$. Alors,

$$0 \leq \mathbb{P}(X \in]a_i, b_i[) \leq \mathbb{P}(X \in [a_i, b_i]) = 0 \leq \mathbb{P}\left(X \in \bigcup_{x \in]a_i, b_i[\cap \mathbb{Q}} V(x)\right) \leq \sum_{x \in]a_i, b_i[\cap \mathbb{Q}} \mathbb{P}(X \in V(x)) = 0.$$

Par conséquent,

$$\mathbb{P}(X \in [a_i, b_i]) = 0$$

donc $[a_i, b_i]$ est négligeable pour la loi de X . I étant au plus dénombrable, $\mathbb{P}(X \in S_f^c) = 0$ donc $\mathbb{P}(X \in S_f) = 1$. On en déduit que $S(X) \subset S_f$.

— $S_f \subset S(X)$: $\mathbb{P}(X \in S(X)) = 1$ donc $\mathbb{P}(X \in S(X)^c) = 0$ et $S(X)^c$ est ouvert. Si $x \in S(X)^c$, avec $V(x) = S(X)^c$ $x \in S_f^c$. Donc $S_f \subset S(X)$. \square

Proposition 2.24

Soit X une variable aléatoire de densité f_X . Soit $g : \mathbb{R}^d \rightarrow \mathbb{R}^d$ un \mathcal{C}^1 -difféomorphisme ($g \in \mathcal{C}^1$, bijective, $g^{-1} \in \mathcal{C}^1$). Alors, $Y = g(X)$ est une variable aléatoire à densité donnée par

$$\forall y \in \mathbb{R}^d, \quad f_Y(y) = f_X(g^{-1}(y)) |Jac(g^{-1}(y))|$$

$$\left| \text{où } |Jac(g(x))| = \left| \det \left(\frac{\partial g_i}{\partial x_j} \right) \right| \right|.$$

▷ On applique le théorème de changement de variable :

$$\mathbb{P}(Y \in B) = \mathbb{P}(g(X) \in B) = \int_{g^{-1}(B)} f_X(x) dx = \int_B f_X(g^{-1}(y)) |Jac(g^{-1}(y))| dy.$$

□

Exemples : – Soit (X, Y) un vecteur aléatoire de densité $f_{(X,Y)}(x, y) = c \mathbf{1}_{[0,1] \times [-1,2]}(x, y) = c \mathbf{1}_{[0,1]}(x) \mathbf{1}_{[-1,2]}(y)$. $f_{(X,Y)}$ est une densité si :

- elle est mesurable : ok ;
- elle est positive : $\Rightarrow c \geq 0$;
- $\int_{\mathbb{R}^2} f_{(X,Y)}(x, y) dx dy = 1$. Or

$$\int_{\mathbb{R}^2} f_{(X,Y)}(x, y) dx dy = 3c$$

donc $f_{(X,Y)}$ est une densité si et seulement si $c = \frac{1}{3}$.

X est variable aléatoire de densité

$$f_X(x) = \int_{\mathbb{R}} f_{(X,Y)}(x, y) dy = \frac{1}{3} \mathbf{1}_{[0,1]}(x) \int_{\mathbb{R}} \mathbf{1}_{[-1,2]}(y) dy = \mathbf{1}_{[0,1]}$$

donc $X \sim \mathcal{U}([0, 1])$.

De même Y est une variable aléatoire de densité

$$f_Y(y) = \frac{1}{3} \mathbf{1}_{[-1,2]}(y)$$

donc $Y \sim \mathcal{U}([-1, 2])$.

– Soit (X, Y) un couple de densité

$$\forall (x, y) \in \mathbb{R}^2, \quad f_{(X,Y)}(x, y) = \frac{1}{3\pi} e^{-\frac{x^2+2xy+5y^2}{6}}.$$

Loi de X :

$$f_X(x) = \frac{1}{3\pi} \int_{\mathbb{R}} e^{-\frac{x^2+2xy+5y^2}{6}} dy = \frac{1}{3} e^{-\frac{x^2}{6}} \int_{-\infty}^{+\infty} e^{-\frac{2xy+5y^2}{6}} dy.$$

Or $2xy + 5y^2 = 5(y + \frac{x}{5})^2 - \frac{x^2}{5}$ donc

$$f_X(x) = \frac{1}{3\pi} e^{-\frac{x^2}{6}} e^{\frac{x^2}{30}} \int_{-\infty}^{+\infty} e^{-\frac{5}{6}(y+\frac{x}{5})^2} dy = \frac{1}{3\pi} e^{-\frac{2x^2}{15}} \underbrace{\sqrt{\frac{3}{5}} \int_{-\infty}^{+\infty} e^{-\frac{z^2}{2}} dz}_{\sqrt{2\pi}}$$

en effectuant le changement de variables $z = \sqrt{\frac{5}{3}}(y + \frac{x}{5})$. Alors,

$$f_X(x) = \sqrt{\frac{2}{15\pi}} e^{-\frac{2x^2}{15}}$$

donc $X \sim \mathcal{N}(0, \frac{15}{4}) = \mathcal{N}(m, \sigma^2)$: loi normale.

Exercice : montrer que la loi de Y est

$$f_Y(y) = \sqrt{\frac{2}{3\pi}} e^{\frac{-2}{3}y^2}.$$

Chapitre 3

Espérance d'une variable aléatoire

Théorème de transfert

Soient (E, \mathcal{E}) , et (F, \mathcal{F}) deux espaces mesurables, $\varphi : (E, \mathcal{E}) \rightarrow (F, \mathcal{F})$ une fonction mesurable et μ une mesure sur (E, \mathcal{E}) . La mesure image $\nu = \mu_\varphi$ définie par

$$\forall B \in \mathcal{F}, \quad \nu(B) = \mu(\varphi^{-1}(B))$$

est une mesure sur (F, \mathcal{F}) .

Théorème 3.1

Soit $h : (F, \mathcal{F}) \rightarrow (\mathbb{R}, \mathcal{B}(\mathbb{R}))$ une fonction mesurable. Alors h est ν -intégrable si et seulement si $h \circ \varphi$ est μ -intégrable et alors

$$\int_F h d\nu = \int_E h \circ \varphi d\mu.$$

3.1 Définition et propriétés de l'espérance d'une variable aléatoire

Soient $(\Omega, \mathcal{F}, \mathbb{P})$ un espace de probabilité et $X : (\Omega, \mathcal{F}) \rightarrow \mathbb{R}^d$ une variable aléatoire soit positive (si $d = 1$), soit intégrable *ie.*

$$\int_{\Omega} |X(\omega)| \mathbb{P}(d\omega) < +\infty$$

Définition 3.2

On définit l'espérance d'une variable aléatoire réelle positive ou intégrable comme

$$\mathbb{E}[X] = \int_{\Omega} X(\omega) \mathbb{P}(d\omega).$$

Si X est à valeurs dans \mathbb{R}^d , $X = (X_1, \dots, X_d)$,

$$\mathbb{E}[X] = (\mathbb{E}[X_1], \dots, \mathbb{E}[X_d]).$$

$\mathbb{E}[X]$ est la valeur moyenne de la variable aléatoire X .

Remarques : – $\mathbb{E}[X] \in \mathbb{R}$ et n'est pas aléatoire!

– Comme les probabilités sont de masse finie, les constantes sont intégrables. Si $X = c$, $\mathbb{E}[X] = c$. En particulier, si X est une variable aléatoire bornée, X est intégrable.

– Si $X = \mathbf{1}_A$ alors $\mathbb{E}[X] = \mathbb{P}(A)$.

– Si X est une fonction étagée positive $X = \sum_{i \in I} a_i \mathbf{1}_{A_i}$ où I est fini, alors

$$\mathbb{E}[X] = \sum_{i \in I} a_i \mathbb{P}(A_i).$$

– Si X est une fonction étagée quelconque, $X = X^+ - X^-$ où $X^+ = \max(X, 0)$, $X^- = \max(-X, 0)$ sont étagées positives et

$$\mathbb{E}[X] = \mathbb{E}[X^+] - \mathbb{E}[X^-].$$

– Si X est une variable aléatoire positive alors X est limite croissante de variables aléatoires X_n étagées positives. Alors,

$$\mathbb{E}[X] = \lim_{n \rightarrow +\infty} \mathbb{E}[X_n] = \sup\{\mathbb{E}[Y], Y \text{ variable aléatoire étagée telle que } Y \leq X\}.$$

– Si X est une variable aléatoire intégrable, ie. $\mathbb{E}[|X|] < \infty$, $X = X^+ - X^-$ où X^+ et X^- sont des variables aléatoires positives. Alors,

$$\mathbb{E}[X] = \mathbb{E}[X^+] - \mathbb{E}[X^-].$$

– Si X est complexe avec $\mathbb{E}[|X|] < \infty$ alors

$$\mathbb{E}[X] = \mathbb{E}[\Re(X)] + i\mathbb{E}[\Im(X)].$$

L'espérance étant définie comme une intégrale, on a les mêmes propriétés que pour l'intégrale.

Théorème 3.3 (convergence monotone)

Si (X_n) est une suite croissante de variables aléatoires positives alors

$$\sup \mathbb{E}[X_n] = \lim_{n \rightarrow +\infty} \mathbb{E}[X_n] = \mathbb{E}[\lim_{n \rightarrow +\infty} X_n] = \mathbb{E}[\sup X_n].$$

Lemme 3.4 (Fatou)

Si (X_n) est une suite de variables aléatoires positives alors

$$\mathbb{E}[\liminf_{n \rightarrow +\infty}] \leq \liminf_{n \rightarrow +\infty} \mathbb{E}[X_n].$$

Théorème 3.5 (convergence dominée)

Si (X_n) est une suite de variables aléatoires qui converge presque sûrement ie.

$$\exists N \in \mathcal{F}, \mathbb{P}(N) = 0, \forall \omega \notin N, X_n(\omega) \xrightarrow[n \rightarrow +\infty]{} X(\omega)$$

et s'il existe une variable aléatoire Y positive telle que $|X_n| \leq Y$ presque sûrement et $\mathbb{E}[Y] < \infty$

alors

$$\lim_{n \rightarrow +\infty} \mathbb{E}[X_n] = \mathbb{E}[X].$$

On a en fait

$$\lim_{n \rightarrow +\infty} \mathbb{E}[|X_n - X|] = 0.$$

Définition 3.6

Soit X une variable aléatoire intégrable. X est dite centrée si $\mathbb{E}[X] = 0$.

Proposition 3.7

Soient X, Y deux variables aléatoires intégrables.

- (i) Si $X \leq Y$ alors $\mathbb{E}[X] \leq \mathbb{E}[Y]$.
- (ii) Si $A, B \in \mathcal{F}$, $A \subset B$ et $X \geq 0$ alors $\mathbb{E}[X\mathbf{1}_A] \leq \mathbb{E}[X\mathbf{1}_B]$.
- (iii) Si $a, b \in \mathbb{R}$, $\mathbb{E}[aX + bY] = a\mathbb{E}[X] + b\mathbb{E}[Y]$.
- (iv) $|\mathbb{E}[X]| \leq \mathbb{E}[|X|]$
- (v) Si X est une variable aléatoire positive telle que $\mathbb{E}[X] = 0$ alors $X = 0$ presque sûrement.

Proposition 3.8

Soit $X : (\Omega, \mathcal{F}, \mathbb{P}) \rightarrow \mathbb{R}$ une variable aléatoire de loi \mathbb{P}_X . X est \mathbb{P} -intégrable si et seulement si

$$\int_{\mathbb{R}} |x| \mathbb{P}_X(dx) < +\infty$$

et alors,

$$\mathbb{E}[X] = \int_{\mathbb{R}} x \mathbb{P}_X(dx).$$

▷ On applique le théorème de transfert avec $\varphi = X$ et $h(x) = x$:

$$\int_{\Omega} h \circ \varphi d\mathbb{P} = \int_{\mathbb{R}} h d\mathbb{P}_X.$$

□

Inégalité de Markov : Si X est une variable aléatoire positive alors

$$\forall t > 0, \quad \mathbb{P}(X \geq t) \leq \frac{\mathbb{E}[X]}{t}.$$

▷ Par définition, $\mathbb{P}(X \geq t) = \mathbb{E}[\mathbf{1}_{\{X \geq t\}}]$. Or $X \geq X\mathbf{1}_{\{X \geq t\}} \geq t\mathbf{1}_{\{X \geq t\}}$. Donc

$$\mathbb{E}[X] \geq \mathbb{E}[t\mathbf{1}_{\{X \geq t\}}] = t\mathbb{P}(X \geq t).$$

□

Proposition 3.9

(i) Si X est une variable aléatoire positive alors

$$\mathbb{E}[X] = \int_0^{+\infty} \mathbb{P}(X \geq t) dt = \int_0^{+\infty} (1 - F_X(t)) dt.$$

(ii) De plus, $\mathbb{E}[X] < \infty$ si et seulement si

$$\sum_{n \geq 0} \mathbb{P}(X \geq n\varepsilon) < +\infty$$

ou

$$\sum_{n \geq 0} 2^n \mathbb{P}(X \geq \varepsilon 2^n) < \infty$$

pour $\varepsilon > 0$.

▷ (i) Par le théorème de Fubini-Tonelli,

$$\int_0^{+\infty} \mathbb{P}(X > t) dt = \int_0^{+\infty} \mathbb{E}[\mathbf{1}_{\{X > t\}}] dt = \mathbb{E} \left[\int_0^{+\infty} \mathbf{1}_{\{X > t\}} dt \right] = \mathbb{E} \left[\int_0^X dt \right] = \mathbb{E}[X].$$

(ii) Pour $t \in [n, n+1]$, $\{X \geq n+1\} \subset \{X \geq t\} \subset \{X \geq n\}$ donc

$$\forall t \in [n, n+1], \quad \mathbb{P}(X > n+1) \leq \mathbb{P}(X > t) \leq \mathbb{P}(X > n)$$

d'où

$$\mathbb{P}(X > n+1) \leq \int_n^{n+1} \mathbb{P}(X > t) dt \leq \mathbb{P}(X > n)$$

et

$$\sum_{n \geq 0} \mathbb{P}(X > n+1) \leq \underbrace{\int_0^{+\infty} \mathbb{P}(X > t) dt}_{\mathbb{E}[X]} \leq \sum_{n \geq 0} \mathbb{P}(X > n).$$

Ainsi, la propriété est vraie pour $\varepsilon = 1$ et on remplace X par $\frac{1}{\varepsilon}X$ pour obtenir le résultat pour tout ε .

On obtient la seconde équivalence en utilisant

$$\begin{aligned} [1, +\infty[&= \bigcup_{n \geq 0} [2^n, 2^{n+1}[\\ 0, +\infty[&= [0, 1[\cup \bigcup_{n \geq 0} [2^n, 2^{n+1}[\end{aligned}$$

et en remarquant que

$$0 \leq \int_0^1 \mathbb{P}(X > t) dt \leq 1.$$

□

Proposition 3.10 (Inégalité de Jensen)

Soient $\varphi : \mathbb{R} \rightarrow \mathbb{R}$ une fonction convexe (donc mesurable) et $X : \Omega \rightarrow \mathbb{R}$ une variable aléatoire intégrable telle que $\varphi \circ X$ est intégrable. Alors

$$\varphi(\mathbb{E}[X]) \leq \mathbb{E}[\varphi(X)].$$

▷ Pour tout x , $\varphi(x) = \sup\{g(x), g \text{ affine} \leq \varphi\}$. Si g est affine, comme \mathbb{E} est une application linéaire,

$$g(\mathbb{E}[X]) = \mathbb{E}[g(X)] \leq \mathbb{E} \left[\sup_{g \text{ affine} \leq \varphi} g(X) \right] \leq \mathbb{E}[\varphi(X)]$$

En passant au sup, on obtient $\varphi(\mathbb{E}[X]) \leq \mathbb{E}[\varphi(X)]$.

□

Exemple : Soit $c \in \mathbb{R}$. On pose $\varphi : x \mapsto x \vee c = \sup(x, c)$ est convexe donc

$$\mathbb{E}[X] \vee c \leq \mathbb{E}[x \vee c]$$

Avec $\varphi : x \mapsto x^2$,

$$\mathbb{E}[X]^2 \leq \mathbb{E}[X^2]$$

Avec $\varphi : x \mapsto e^x$,

$$e^{\alpha \mathbb{E}[X]} \leq \mathbb{E}[e^{\alpha X}].$$

3.2 Exemples de calcul d'espérance

3.2.1 Variables discrètes

Soit X une variable aléatoire à valeurs dans $\mathcal{A} = \{x_i, i \in I\}$ où I est au plus dénombrable. Sa loi est

$$\mathbb{P}_X = \sum_{i \in I} \underbrace{\mathbb{P}(X = x_i)}_{p_i} \delta_{x_i}.$$

Alors X est intégrable si $\mathbb{E}[|X|] = \sum_{i \in I} |x_i| p_i < \infty$ (c'est le cas par exemple si $\#I < \infty$) et dans ce cas,

$$\mathbb{E}[X] = \sum_{i \in I} p_i$$

Si $h : \mathbb{R} \rightarrow \mathbb{R}$ est mesurable, $h \circ X$ est une variable aléatoire discrète intégrable si

$$\mathbb{E}[|h(X)|] = \sum_{i \in I} |h(x_i)| p_i < \infty$$

et dans ce cas

$$\mathbb{E}[h(X)] = \sum_{i \in I} h(x_i) p_i.$$

Exemples : – Si $X = c$ est constante, $\mathcal{E}[X] = c$.

– Si X est à valeurs dans $\{0, 1\}$ et suit la loi $\mathcal{B}(p)$:

$$\mathbb{P}(X = 0) = 1 - p \quad \mathbb{P}(X = 1) = p$$

alors

$$\mathbb{E}[X] = 0 \times (1 - p) + 1 \times p = p.$$

\triangle Si X est à valeurs dans $\{a, b\}$, $\mathbb{P}(X = a) = 1 - p$, $\mathbb{P}(X = b) = p$ et

$$\mathbb{E}[X] = a(1 - p) + bp.$$

– Si X est équirépartie sur $\mathcal{A} = \{x_1, \dots, x_n\}$ deux à deux distincts.

$$\mathbb{E}[X] = \sum_{i=1}^n x_i \frac{1}{n}$$

est la moyenne arithmétique des x_i .

– Si $X \sim \mathcal{B}(n, p)$ $X \in \llbracket 0, n \rrbracket$ (où n est le nombre d'expériences et p la probabilité de succès)

$$\mathbb{P}(X = k) = \binom{n}{k} p^k (1-p)^{n-k}$$

et

$$\begin{aligned} \mathbb{E}[X] &= \sum_{k=0}^n k \binom{n}{k} p^k (1-p)^{n-k} = \sum_{k=1}^n n \binom{n-1}{k-1} p^k (1-p)^{n-k} \\ &= np \sum_{k=1}^n \binom{n-1}{k-1} p^{k-1} (1-p)^{(n-1)-(k-1)} = np \sum_{i=0}^{n-1} \binom{n-1}{i} p^i (1-p)^{(n-1)-i} = np. \end{aligned}$$

– $X \sim \text{Geom}(p)$ avec $X \in \mathbb{N}^*$.

$$\mathbb{P}(X = k) = p(1-p)^{k-1} \quad k \geq 1$$

$$\mathbb{E}[X] = \sum_{k=1}^{+\infty} kp(1-p)^{k-1} = p \sum_{k=1}^{+\infty} k(1-p)^{k-1} = p \times \frac{1}{(1-1+p)^2} = \frac{1}{p}$$

– $X \sim \mathcal{P}(\lambda)$ $X \in \mathbb{N}$ et

$$\begin{aligned} \mathbb{P}(X = k) &= \frac{\lambda^k}{k!} e^{-\lambda} \\ \mathbb{E}[X] &= \sum_{k=0}^{\infty} k \frac{\lambda^k}{k!} e^{-\lambda} = \sum_{k=1}^{\infty} \frac{\lambda^k}{(k-1)!} e^{-\lambda} = \lambda. \end{aligned}$$

3.2.2 Variables aléatoires à densité

Soit $X : (\Omega, \mathcal{F}, \mathbb{P}) \rightarrow \mathbb{R}$ une variable aléatoire à densité. X est intégrable si et seulement si $\int_{\mathbb{R}} |x|f(x)dx < \infty$ et dans ce cas

$$\mathbb{E}[X] = \int_{\mathbb{R}} xf(x)dx.$$

Remarque : Si X est bornée alors elle est intégrable car $\int f = 1$.

Si $h : \mathbb{R} \rightarrow \mathbb{R}$ est mesurable, si $\mathbb{E}[|h(X)|] = \int_{\mathbb{R}} |h(x)|f(x)dx < \infty$ alors

$$\mathbb{E}[h(X)] = \int_{\mathbb{R}} h(x)f(x)dx.$$

Exemples : – Si $X \sim \mathcal{U}([a, b])$ alors $f : x \mapsto \frac{1}{b-a} \mathbf{1}_{[a,b]}(x)$, X est bornée et

$$\mathbb{E}[X] = \int_{\mathbb{R}} x \frac{1}{b-a} \mathbf{1}_{[a,b]}(x)dx = \frac{a+b}{2}$$

– Si $X \sim \text{Exp}(\alpha)$ $\alpha \geq 0$ alors

$$f : x \mapsto \alpha e^{-\alpha x} \mathbf{1}_{x \geq 0}$$

X est intégrable

$$\mathbb{E}[X] = \int_0^{+\infty} x \alpha e^{-\alpha x} dx = \frac{1}{\alpha}$$

– X suit la loi de Cauchy de paramètre $a > 0$:

$$\begin{aligned} \mathbb{R} &\rightarrow \mathbb{R} \\ f : x &\mapsto \frac{a}{\pi a^2 + x^2} \end{aligned}$$

comme $x \mapsto \frac{|x|}{a^2 + x^2}$ n'est pas intégrable, X n'est pas intégrable donc $\mathbb{E}[X]$ n'existe pas.
– $X \sim \mathcal{N}(0, 1)$

$$\begin{aligned} \mathbb{R} &\rightarrow \mathbb{R} \\ f : x &\mapsto \frac{1}{\sqrt{2\pi}} e^{-\frac{x^2}{2}} \end{aligned}$$

$x \mapsto |x|e^{-\frac{x^2}{2}}$ est intégrable sur \mathbb{R} donc

$$\mathbb{E}[X] = \int_{\mathbb{R}} \frac{1}{\sqrt{2\pi}} x e^{-\frac{x^2}{2}} dx = 0$$

Exercice : $\forall p \geq 0$, X^p est intégrable. Montrer que

$$\begin{cases} \mathbb{E}[X^{2k+1}] = 0 \\ \mathbb{E}[X^{2k}] = \frac{(2k)!}{2^k k!} \end{cases}$$

Proposition 3.11

Soit $m \in \mathbb{R}$ et $\sigma^2 > 0$.

$$X \sim \mathcal{N}(m, \sigma^2) \quad \Longleftrightarrow \quad Z = \frac{X - m}{\sigma} \sim \mathcal{N}(0, 1)$$

Conséquence : $X = m + \sigma Z$ donc $\mathbb{E}[X] = m + \sigma \mathbb{E}[Z] = m$.

▷ Si $X \sim \mathcal{N}(m, \sigma^2)$,

$$\mathbb{P}(Z \leq t) = \mathbb{P}\left(\frac{X - m}{\sigma} \leq t\right) = \mathbb{P}(X \leq m + \sigma t) = \int_{-\infty}^{m + \sigma t} \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{(x-m)^2}{2\sigma^2}} dx = \int_{-\infty}^t \frac{1}{\sqrt{2\pi}} e^{-\frac{x^2}{2}} dx$$

donc $Z \sim \mathcal{N}(0, 1)$. La réciproque se démontre en remontant le calcul □

3.2.3 Identification de la loi d'une variable aléatoire

Théorème 3.12

Soit $X : (\Omega, \mathcal{F}, \mathbb{P}) \rightarrow (\mathbb{R}^d, \mathcal{B}(\mathbb{R}^d))$ une variable aléatoire. Soit μ une mesure de probabilité sur $(\mathbb{R}^d, \mathcal{B}(\mathbb{R}^d))$. Les assertions suivantes sont équivalentes :

- (i) La loi de X est égale à μ .
- (ii) $\forall A \in \mathcal{B}(\mathbb{R}) \mathbb{P}(X \in A) = \mu(A)$
- (iii) $\forall (t_1, \dots, t_d) \in \mathbb{R}^d, \mathbb{P}(X_1 \leq t_1, \dots, X_d \leq t_d) = \mu\left(\prod_{i=1}^d]-\infty, t_i]\right)$
- (iv) $\forall h$ mesurable positive $\mathbb{E}[h(X)] = \int_{\mathbb{R}^d} h d\mu$
- (v) $\forall h \in \mathcal{C}_c^\infty(\mathbb{R}^d) \mathbb{E}[h(X)] = \int_{\mathbb{R}^d} h d\mu$.

Exemple : $X \sim \mathcal{U}(]0, 1[)$ et $Y = \ln(X)$. Soit h une fonction mesurable positive

$$\mathbb{E}[h(Y)] = \mathbb{E}[h(-\ln(X))] = \int_0^1 h(-\ln(x)) dx = \int_0^{+\infty} h(y) e^{-y} dy = \int_0^{+\infty} h \mathbb{P}_Y(dy)$$

donc

$$Y \sim \text{Exp}(1)$$

▷ (v) \Rightarrow (ii) Soit K un compact de \mathbb{R}^d et G un ouvert tel que $K \subset G$ et \overline{G} compact.

$$\tilde{h} : x \mapsto \frac{d(x, G^c)}{d(x, K) + d(x, G^c)}$$

est continue à valeurs dans $[0, 1]$ et à support compact. $\forall x \in K, h(x) = 1$ et $\mathbf{1}_K(x) \leq h(x) \leq \mathbf{1}_G(x)$.

On construit une suite décroissante (G_n) d'ouverts tels que $\bigcap G_n = K$. On le fait en dimension 1 :

$$K_n = \frac{d(x, G_n^c)}{d(x, K) + d(x, G_n^c)} \xrightarrow{n \rightarrow +\infty} \mathbf{1}_K(x)$$

De plus $(h_n)_n$ est décroissante positive donc par le théorème de convergence dominée,

$$\mathbb{E}[h_n(X)] \xrightarrow{n \rightarrow +\infty} \mathbb{E}[\mathbf{1}_K(x)] = \mathbb{P}(X \in K)$$

Par hypothèse $\int h_n d\mu \xrightarrow[n \rightarrow +\infty]{\mu} (K)$ on a pour tout compact $\mathbb{P}(X \in K) = \mu(K)$ puis $\mathbb{P}(X \in A) = \mu(A)$ pour tout $A \in \mathcal{B}(\mathbb{R})$. \square

3.3 Moments d'une variable aléatoire

Définition 3.13

Soit $X : (\Omega, \mathcal{F}, \mathbb{P}) \rightarrow E = \mathbb{R}, \mathbb{C}, \mathbb{R}^d$, ou \mathbb{C}^d . On dit que X a un moment d'ordre $p > 0$ fini si $\mathbb{E}[|X|^p] < \infty$ et alors le moment d'ordre p de X est $\mathbb{E}[X^p]$.

Définition 3.14

On définit l'espace

$$\mathcal{L}^p = \{X : (\Omega, \mathcal{F}, \mathbb{P}) \rightarrow \mathbb{E} \text{ variable aléatoire telle que } \mathbb{E}[|X|^p] < \infty\}$$

pour $p \in]0, +\infty[$ et

$\mathcal{L}^\infty = \{X : (\Omega, \mathcal{F}, \mathbb{P}) \rightarrow \mathbb{R} \text{ variable aléatoire telle qu'il existe } C > 0, \mathbb{P}(X > C) = 0\}.$

On réutilise les espaces L^p vus en intégration.

Théorème 3.15 (Inégalité de Hölder)

Soient $p, q \geq 1$ tels que $\frac{1}{p} + \frac{1}{q} = 1$. Soient $X \in L^p(\Omega, \mathcal{F}, \mathbb{P})$ et $Y \in L^q(\Omega, \mathcal{F}, \mathbb{P})$. Alors

$$XY \in L^1(\Omega, \mathcal{F}, \mathbb{P}) \quad \text{et} \quad \mathbb{E}[|XY|] \leq \mathbb{E}[|X|^p]^{\frac{1}{p}} \mathbb{E}[|Y|^q]^{\frac{1}{q}}$$

Corollaire 3.16 (Inégalité de Cauchy-Schwarz)

$$X, Y \in L^2(\Omega, \mathcal{F}, \mathbb{P}) \implies XY \in L^1(\Omega, \mathcal{F}, \mathbb{P}) \quad \text{et} \quad \mathbb{E}[|XY|] \leq \mathbb{E}[|X|^2]^{\frac{1}{2}} \mathbb{E}[|Y|^2]^{\frac{1}{2}}.$$

▷ On a

$$\forall a \in \mathbb{R}, \quad \mathbb{E}[(aX + Y)^2] = a^2 \mathbb{E}[X^2] + 2a \mathbb{E}[XY] + \mathbb{E}[Y^2] = \mathbb{E}[(aX + Y)^2] \geq 0$$

donc

$$\delta = \mathbb{E}[XY]^2 - \mathbb{E}[X^2] \mathbb{E}[Y^2] \leq 0$$

d'où le résultat. □

Cas d'égalité : si on a égalité dans l'inégalité de Cauchy-Schwarz, $\delta' = 0$ et donc il existe $a \in \mathbb{R}$ tel que

$$\mathbb{E}[(aX + Y)^2] = 0$$

donc $aX + Y = 0$ ps. Ainsi, il y a égalité dans l'inégalité de Cauchy-Schwarz si et seulement s'il existe une relation linéaire entre X et Y .

Théorème 3.17 (Inégalité de Minkowski)

Soient X, Y deux variables aléatoires dans L^p , $1 \leq p \leq +\infty$ alors

$$\|X + Y\|_p \leq \|X\|_p + \|Y\|_p$$

Théorème 3.18

Si $1 \leq p \leq q \leq +\infty$, alors

$$L^\infty \subset L^q \subset L^p \subset L^1$$

et $p \mapsto \|\cdot\|_p$ est une fonction croissante.

Théorème 3.19 (Riesz-Fisher)

Soit $p \geq 1$. $(L^p(\Omega, \mathcal{F}, \mathbb{P}), \|\cdot\|_p)$ est un espace vectoriel normé complet.

$L^2(\Omega, \mathcal{F}, \mathbb{P})$ muni du produit scalaire $\langle X, Y \rangle = \mathbb{E}[XY]$ est un espace de Hilbert.

3.4 Variance et covariance

Définition 3.20

Soit $X \in L^2(\Omega, \mathcal{F}, \mathbb{P})$. On définit la variance de X comme

$$\text{Var}(X) = \mathbb{E}[(X - \mathbb{E}[X])^2]$$

et l'écart-type de X comme

$$\sigma_X = \sqrt{\text{Var}(X)}.$$

Exemple : Soient X et Y de lois respectives

$$\mathbb{P}_X = \frac{1}{2}\delta_{-1} + \frac{1}{2}\delta_1, \quad \mathbb{P}_Y = \frac{1}{2}\delta_{-100} + \frac{1}{2}\delta_{100}.$$

Alors

$$\mathbb{E}[X] = 0 = \mathbb{E}[Y]$$

mais

$$\sigma(X) = 1 \quad \text{et} \quad \sigma(Y) = 100.$$

Remarque : L'espérance donne la valeur moyenne d'une variable aléatoire et l'écart-type donc la distance moyenne entre la variable aléatoire et son espérance. Plus l'écart-type est grand, plus la variable aléatoire est diffuse. Plus l'écart-type est proche de zéro, plus la variable aléatoire est concentrée autour de sa moyenne. C'est une mesure de dispersion.

Proposition 3.21

Soit X une variable aléatoire dans L^2 .

- (i) $\text{Var}(X) \geq 0$.
- (ii) $\text{Var}(X) = 0$ si et seulement si $X = \mathbb{E}[X]$ presque sûrement.
- (iii) $\text{Var}(X) = \mathbb{E}[X^2] - \mathbb{E}[X]^2$.
- (iv) $\forall a, b \in \mathbb{R}, \quad \text{Var}(aX + b) = a^2 \text{Var}(X)$.

▷ (iii) En développant le carré, on obtient :

$$\text{Var}(X) = \mathbb{E}[X^2 - 2\mathbb{E}[X]X + \mathbb{E}[X]^2] = \mathbb{E}[X^2] - 2\mathbb{E}[X]\mathbb{E}[X] + \mathbb{E}[X]^2 = \mathbb{E}[X^2] - \mathbb{E}[X]^2.$$

(iv) On a :

$$\text{Var}(aX) = a^2\mathbb{E}[X^2] - a^2\mathbb{E}[X]^2 = a^2 \text{Var}(X)$$

et

$$\text{Var}(X + b) = \mathbb{E}[(X + b - (\mathbb{E}[X] + b))^2] = \text{Var}(X).$$

□

Exemples : — Si X est une variable aléatoire discrète à valeurs dans $\mathcal{A} = \{x_i, i \in I\}$ avec I au plus dénombrable. Alors, en notant $p_i = \mathbb{P}(X = x_i)$.

$$\text{Var}(X) = \sum_{i \in I} (x_i - \mathbb{E}[X])^2 p_i = \sum_{i \in I} x_i^2 p_i - \left(\sum_{i \in I} x_i p_i \right)^2$$

- Si $\mathbb{P}_X = \delta_a$ alors $\text{Var}(X) = 0$.
- Si $X \sim \mathcal{B}(p)$ avec $p \in]0, 1[$,

$$\mathbb{E}[X] = p \quad \text{et} \quad \mathbb{E}[X^2] = 0^2 \times (1-p) + 1^2 \times p = p$$

donc

$$\text{Var}(X) = p - p^2 = p(1-p).$$

- Si $X \sim \text{Geom}(p)$ alors $\forall k \geq 1$, $\mathbb{P}(X = k) = (1-p)^{k-1}p$ donc

$$\mathbb{E}[X] = \frac{1}{p} \quad \text{et} \quad \mathbb{E}[X^2] = \sum_{k=1}^{+\infty} k^2 (1-p)^{k-1} p$$

Or $k^2 = k(k-1) + k$ donc

$$\mathbb{E}[X^2] = p(1-p) \sum_{k=1}^{+\infty} k(k-1)(1-p)^{k-2} + \sum_{k=1}^{+\infty} k(1-p)^{k-1} p = p(1-p) \frac{2}{(1-(1-p))^3} + \frac{1}{p} = \frac{2}{p^2} - \frac{1}{p}.$$

Alors,

$$\text{Var}(X) = \frac{2}{p^2} - \frac{1}{p} - \left(\frac{1}{p}\right)^2 = \frac{1}{p^2} - \frac{1}{p} = \frac{p-1}{p^2}.$$

- Montrer que si $X \sim \mathcal{B}(n, p)$ alors

$$\text{Var}(X) = np(1-p).$$

Montrer que si $X \sim \mathcal{P}(\lambda)$ alors

$$\text{Var}(X) = \lambda.$$

- Si X est une variable aléatoire à densité f_X dans L^2 alors

$$\text{Var}(X) = \int_{\mathbb{R}} (x - \mathbb{E}[X])^2 f_X(\mathrm{d}x) = \int_{\mathbb{R}} x^2 f_X(\mathrm{d}x) - \left(\int_{\mathbb{R}} x f_X(\mathrm{d}x) \right)^2.$$

- Si $X \sim \mathcal{U}([a, b])$,

$$\mathbb{E}[X] = \frac{a+b}{2} \quad \text{et} \quad \mathbb{E}[X^2] = \frac{1}{b-a} \int_a^b x^2 \mathrm{d}x = \frac{b^3 - a^3}{3(b-a)} = \frac{b^2 + ab + a^2}{3}$$

donc

$$\text{Var}(X) = \frac{4(b^2 + ab + a^2) - 3(a+b)^2}{12} = \frac{(b-a)^2}{12}.$$

- Si $X \sim \text{Exp}(\alpha)$ alors $f_X(x) = \alpha e^{-\alpha x} \mathbf{1}_{x>0}$ donc

$$\mathbb{E}[X] = \frac{1}{\alpha}$$

et

$$\mathbb{E}[X^2] = \int_0^{+\infty} \alpha x^2 e^{-\alpha x} \mathrm{d}x = \left[\left(-x^2 - \frac{2x}{\alpha} - \frac{2}{\alpha^2} \right) e^{-\alpha x} \right]_0^{+\infty} = \frac{2}{\alpha^2}$$

donc

$$\text{Var}(X) = \frac{2}{\alpha^2} - \frac{1}{\alpha^2} = \frac{1}{\alpha^2}.$$

– Si $X \sim \mathcal{N}(0, 1)$ alors

$$\mathbb{E}[X] = 0$$

donc

$$\text{Var}(X) = \mathbb{E}[X^2] = \frac{1}{\sqrt{2\pi}} \int_{-\infty}^{+\infty} x^2 e^{-\frac{x^2}{2}} dx$$

Par intégration par parties ($u(x) = x$ et $v(x) = xe^{-\frac{x^2}{2}}$), on obtient

$$\text{Var}(X) = \frac{1}{\sqrt{2\pi}} \left[-xe^{-\frac{x^2}{2}} \right]_{-\infty}^{+\infty} + \frac{1}{\sqrt{2\pi}} \int_{-\infty}^{+\infty} e^{-\frac{x^2}{2}} dx = 1.$$

Si $X \sim \mathcal{N}(m, \sigma^2)$ on peut écrire $X = m + \sigma Z$ avec $Z \sim \mathcal{N}(0, 1)$ ($Z = \frac{X-m}{\sigma}$). Alors,

$$\text{Var}(X) = \text{Var}(m + \sigma Z) = \text{Var}(\sigma Z) = \sigma^2 \text{Var}(Z) = \sigma^2.$$

Théorème 3.22 (Inégalité de Bienaymé-Tchebychev)

Soit X une variable aléatoire dans $L^2(\Omega, \mathcal{F}, \mathbb{P})$. Alors,

$$\forall a > 0, \quad \mathbb{P}(|X - \mathbb{E}[X]| > a) \leq \frac{\text{Var}(X)}{a^2}.$$

$$\triangleright \quad \mathbb{P}(|x - \mathbb{E}[X]| > a) = \mathbb{P}((X - \mathbb{E}[X])^2 > a^2) \underset{\text{Markov}}{\leq} \frac{\mathbb{E}[(X - \mathbb{E}[X])^2]}{a^2} = \frac{\text{Var}(X)}{a^2}. \quad \square$$

Application : Combien de fois faut-il jouer à Pile ou Face avec une pièce bien équilibrée pour que la proportion de piles soit dans l'intervalle $[\frac{1}{2} - 0,01, \frac{1}{2} + 0,01]$ avec probabilité supérieure à 0,96 ? Notons X le nombre de piles sur n lancers. Alors, $X \sim \mathcal{B}(n, \frac{1}{2})$. On cherche n tel que $\mathbb{P}(\frac{X}{n} \in [\frac{1}{2} - 0,01, \frac{1}{2} + 0,01]) \geq 0,96$. Mais

$$\mathbb{P}\left(\frac{X}{n} \in \left[\frac{1}{2} - 0,01, \frac{1}{2} + 0,01\right]\right) = \mathbb{P}\left(\left|X - \frac{n}{2}\right| \leq 0,01n\right) = 1 - \mathbb{P}\left(\left|X - \frac{n}{2}\right| > 0,01n\right) \geq 1 - \frac{\text{Var}(X)}{(0,01n)^2}.$$

Or $\text{Var}(X) = \frac{n}{4}$ donc on a le résultat si n vérifie

$$1 - \frac{1}{4 \cdot 10^{-4} n} \geq 0,96 \quad \Longleftrightarrow \quad n \geq \frac{1}{0,0004 \times 0,04} = 62500.$$

Si X est une variable aléatoire dans \mathbb{R}^d , $d > 1$, que faire ? Si $d = 2$, on définit la quantité suivante.

Définition 3.23

Soient X, Y deux variables aléatoires réelles dans L^2 . La covariance de (X, Y) est définie par

$$\text{cov}(X, Y) = \mathbb{E}[(X - \mathbb{E}[X])(Y - \mathbb{E}[Y])].$$

Proposition 3.24

- (i) $(X, Y) \mapsto \text{cov}(X, Y)$ est une application bilinéaire.
- (ii) $\text{cov}(X, X) = \text{Var}(X)$.
- (iii) $\forall a \in \mathbb{R}, \quad \text{cov}(X, a) = 0$.
- (iv) $\text{cov}(X, Y) = \mathbb{E}[XY] - \mathbb{E}[X]\mathbb{E}[Y]$ donc si X ou Y est centrée, $\text{cov}(X, Y) = \mathbb{E}[XY]$.
- (v) $\text{Var}(X + Y) = \text{Var}(X) + \text{Var}(Y) + 2 \text{cov}(X, Y)$.

▷ (v) $\text{Var}(X + Y) = \mathbb{E}[(X + Y - \mathbb{E}[X + Y])^2] = \mathbb{E}[(X - \mathbb{E}[X]) + (Y - \mathbb{E}[Y])]^2$ donc

$$\text{Var}(X + Y) = \text{Var}(X) + \text{Var}(Y) + 2 \text{cov}(X, Y).$$

□

Définition 3.25

Le coefficient de corrélation de $X, Y \in L^2$ (non constantes) est

$$\rho(X, Y) = \frac{\text{cov}(X, Y)}{\sigma(X)\sigma(Y)}.$$

Remarque : $\rho(X, Y) \in [-1, 1]$ d'après l'inégalité de Cauchy-Schwarz. Si $|\rho(X, Y)| = 1$ alors il y a égalité dans l'inégalité de Cauchy-Schwarz et donc il existe une relation linéaire entre $X - \mathbb{E}[X]$ et $Y - \mathbb{E}[Y]$ et donc une relation affine entre X et Y :

$$Y = aX + b \quad \text{avec} \quad \begin{cases} a = \frac{\text{cov}(X, Y)}{\text{Var}(X)} \\ b = \mathbb{E}[Y] - a\mathbb{E}[X] \end{cases}$$

Définition 3.26

Soit (X_1, \dots, X_d) un vecteur aléatoire dans L^2 . On appelle matrice de covariance la matrice

$$\Gamma = (\text{cov}(X_i, X_j))_{1 \leq i, j \leq d}$$

Γ est une matrice symétrique et pour tout $1 \leq i \leq d$, $\Gamma_{i,i} = \text{Var}(X_i)$. De plus, si $X = (X_1, \dots, X_d)^T$, on peut écrire

$$\Gamma = \mathbb{E}[XX^T] - \mathbb{E}[X]\mathbb{E}[X]^T = \mathbb{E}[(X - \mathbb{E}[X])(X - \mathbb{E}[X])^T].$$

Ainsi, Γ est une matrice positive :

$$\forall a \in \mathbb{R}^d, \quad a^T \Gamma a = \mathbb{E}[a^T (X - \mathbb{E}[X])(a^T (X - \mathbb{E}[X]))^T] = \mathbb{E}[|a^T (X - \mathbb{E}[X])|^2] \geq 0.$$

Chapitre 4

Fonction caractéristique

4.1 Définition

Définition 4.1

Soit $X : (\Omega, \mathcal{F}, \mathbb{P}) \rightarrow \mathbb{R}^d$ un vecteur aléatoire. On définit la fonction caractéristique de X par

$$\forall t \in \mathbb{R}^d, \quad \varphi_X(t) = \mathbb{E}[e^{i\langle t, X \rangle}] = \int_{\Omega} e^{i\langle t, X(\omega) \rangle} \mathbb{P}(d\omega) = \int_{\mathbb{R}^d} e^{i\langle t, x \rangle} \mathbb{P}(dx).$$

Remarque : φ_X est bien définie sur \mathbb{R}^d car $|e^{i\langle t, X \rangle}| \leq 1$ donc intégrable.

Théorème 4.2

La fonction caractéristique caractérise la loi d'une variable aléatoire : si X et Y sont deux variables aléatoires telles que $\varphi_X = \varphi_Y$ alors $\mathbb{P}_X = \mathbb{P}_Y$.

▷ On démontre le théorème en dimension 1. Soit g une fonction continue à support compact. Exprimons $\mathbb{E}[g(X)]$ à l'aide de φ_X . On remarque que, par le théorème de convergence dominée,

$$g(x) = \lim_{\lambda \rightarrow 0^+} \frac{1}{2\pi} \int_{\mathbb{R}} g(x - t) \frac{2}{1 + t^2} dt.$$

Alors, par le théorème de convergence dominée,

$$\begin{aligned} \mathbb{E}[g(X)] &= \mathbb{E} \left[\lim_{\lambda \rightarrow 0} \frac{1}{2\pi} \int_{\mathbb{R}} g(X - \lambda t) \frac{2}{1 + t^2} dt \right] = \lim_{\lambda \rightarrow 0} \mathbb{E} \left[\frac{1}{2\pi} \int_{\mathbb{R}} g(X - \lambda t) \frac{2}{1 + t^2} dt \right] \\ &= \lim_{\lambda \rightarrow 0} \int_{\mathbb{R}} \frac{1}{2\pi} \int_{\mathbb{R}} g(x - \lambda t) \frac{2}{1 + t^2} dt \mathbb{P}_X(dx) = \lim_{s=x-\lambda t} \int_{\mathbb{R}} \frac{1}{2\pi} \int_{\mathbb{R}} f(s) \frac{2}{1 + \left(\frac{x-s}{\lambda}\right)^2} \frac{ds}{\lambda} \mathbb{P}_X(dx) \\ &\stackrel{\text{Fubini}}{=} \lim_{\lambda \rightarrow 0} \int_{\mathbb{R}} g(s) \left(\frac{1}{2\pi} \int_{\mathbb{R}} \frac{2\lambda}{\lambda^2 + (x-s)^2} \mathbb{P}_X(dx) \right) ds \end{aligned}$$

Or

$$\begin{aligned} \frac{2\lambda}{\lambda^2 + (x-s)^2} &= \frac{1}{\lambda + i(x-s)} + \frac{1}{\lambda - i(x-s)} = \int_0^{+\infty} e^{-(\lambda+i(x-s)u)} du + \int_0^{+\infty} e^{-(\lambda-i(x-s)u)} du \\ &= \int_{-\infty}^{+\infty} e^{\lambda|u|-i(x-s)u} du \end{aligned}$$

donc

$$\begin{aligned} E(g(X)) &= \lim_{\lambda \rightarrow 0} \int_{\mathbb{R}} g(s) \frac{1}{2\pi} \left(\int_{\mathbb{R}} \left(\int_{\mathbb{R}} e^{\lambda|u|-i(x-s)u} du \right) \mathbb{P}_X(dx) \right) ds \\ &\stackrel{\text{Fubini}}{=} \lim_{\lambda \rightarrow 0} \int_{\mathbb{R}} \frac{g(s)}{2\pi} \left(\int_{\mathbb{R}} e^{-\lambda|u|} e^{isu} \left(\underbrace{\int_{\mathbb{R}} e^{-ixu} \mathbb{P}_X(dx)}_{\varphi_X(-u)} \right) du \right) ds = \mathbb{E}[g(Y)] \end{aligned}$$

si $\varphi_X = \varphi_Y$ et ce pour tout fonction g continue à support compact. On a finalement

$$\mathbb{E}[g(X)] = \int_{\mathbb{R}} \frac{g(s)}{2\pi} \int_{\mathbb{R}} e^{isu} \varphi_X(-u) du ds.$$

On a pu appliquer les théorèmes de Fubini et de convergence dominée car

$$\left| \frac{g(s)}{2\pi} e^{-\lambda|u|} e^{-i(x-s)u} \right| \leq \frac{1}{2\pi} |g(s)| e^{-|u|} \in L^1(ds \otimes du \otimes \mathbb{P}_X(dx))$$

□

Pour trouver la loi d'une variable aléatoire on peut utiliser :

- si X est discrète : $\mathbb{P}(X = x_k)$,
- la fonction de répartition,
- $\mathbb{E}[h(X)]$ pour h mesurable bornée,
- φ_X .

4.2 Propriétés

Proposition 4.3

Soit X un vecteur aléatoire de fonction caractéristique φ_X .

- (i) $\forall t \in \mathbb{R}^d, \quad |\varphi_X(t)| \leq 1.$
- (ii) $\forall t \in \mathbb{R}^d, \quad \varphi_X(t) = \varphi_X(-t).$
- (iii) $\varphi_X(0) = 1.$
- (iv) $t \mapsto \varphi_X(t)$ est uniformément continue sur \mathbb{R}^d .

▷ Soient $t, h \in \mathbb{R}^d$,

$$\varphi_X(t+h) - \varphi_X(t) = \mathbb{E} [e^{i\langle t+h, X \rangle} - e^{i\langle t, X \rangle}] = \mathbb{E} \left[e^{i\langle t+\frac{h}{2}, X \rangle} \left(\underbrace{e^{i\langle \frac{h}{2}, X \rangle} - e^{-i\langle \frac{h}{2}, X \rangle}}_{2i \sin(\langle \frac{h}{2}, X \rangle)} \right) \right]$$

donc

$$|\varphi_X(t+h) - \varphi_X(t)| \leq \mathbb{E} \left[2 \left| \sin \left\langle \frac{h}{2}, X \right\rangle \right| \right] \leq 2 \mathbb{E} \left[\min \left(\left| \left\langle \frac{h}{2}, X \right\rangle \right|, 1 \right) \right] \xrightarrow{\|h\| \rightarrow 0} 0$$

uniformément en t , par le théorème de convergence dominée. Donc φ_X est uniformément continue. \square

Exemples : – Si X est discrète à valeurs dans $\mathcal{A} = \{x_k, k \in I\}$,

$$\varphi_X(t) = \sum_{k \in I} e^{itx_k} \mathbb{P}(X = x_k).$$

– Si $X \sim \mathcal{B}(p)$,

$$\varphi_X(t) = \mathbb{E}[e^{itX}] = pe^{it} + (1-p).$$

– Si $X \sim \mathcal{B}(n, p)$, on a pour $k \in \llbracket 0, n \rrbracket$

$$\mathbb{P}(X = k) = \binom{n}{k} p^k (1-p)^{n-k}$$

donc

$$\varphi_X(t) = \sum_{k=0}^n \binom{n}{k} p^k (1-p)^{n-k} e^{itk} = (pe^{it} + 1-p)^n.$$

– Si $X \sim \text{Geom}(p)$, pour $k \in \llbracket 1, n \rrbracket$,

$$\mathbb{P}(X = k) = p(1-p)^{k-1}$$

donc

$$\varphi_X(t) = \sum_{k=1}^{+\infty} e^{itk} p(1-p)^{k-1} = \frac{pe^{it}}{1 - e^{it}(1-p)}.$$

– Si X est une variable à densité,

$$\varphi_X(t) = \mathbb{E}[e^{itX}] = \int_{\mathbb{R}} e^{itx} f_X(x) dx.$$

– Si $X \sim \mathcal{U}([a, b])$,

$$\varphi_X(t) = \frac{1}{b-a} \int_a^b e^{itx} dx = \frac{e^{itb} - e^{ita}}{(b-a)it}.$$

– Si $X \sim \text{Exp}(\alpha)$, $\alpha > 0$,

$$f_X(x) = \alpha e^{-\alpha x} \mathbf{1}_{x>0}$$

donc

$$\varphi_X(t) = \int_0^{+\infty} \alpha e^{itx} e^{-\alpha x} dx = \frac{\alpha}{it - \alpha} \left[e^{(it-\alpha)x} \right]_0^{+\infty} = \frac{\alpha}{\alpha - it}.$$

– Si $X \sim \mathcal{N}(0, 1)$,

$$\varphi_X(t) = \int_{-\infty}^{+\infty} e^{itx} \frac{e^{-\frac{x^2}{2}}}{\sqrt{2\pi}} dx = \frac{1}{\sqrt{2\pi}} \int_{-\infty}^{+\infty} e^{-\frac{(x-it)^2}{2}} e^{-\frac{t^2}{2}} dx = e^{-\frac{t^2}{2}}$$

– Si $X \sim \mathcal{N}(m, \sigma^2)$, alors $X = m + \sigma Z$ où $Z \sim \mathcal{N}(0, 1)$ donc

$$\varphi_X(t) = \mathbb{E}[e^{it(m+\sigma Z)}] = e^{itm} \varphi_Z(t\sigma) = e^{itm} e^{-\frac{t^2 \sigma^2}{2}}.$$

– Si X suit la loi de Cauchy de paramètre a : $\mathbb{P}_X = \frac{a}{\pi(a^2+x^2)}dx$

$$\varphi_X(t) = e^{-a|t|}.$$

Proposition 4.4

Soit X une variable aléatoire réelle de fonction caractéristique φ_X . Si X admet un moment d'ordre $p \geq 1$ fini alors φ_X est de classe \mathcal{C}^p et

$$\forall k \leq p, \quad \varphi^{(k)}(0) = i^k \mathbb{E}[X^k].$$

▷ $h : t \mapsto e^{itX}$ est de classe \mathcal{C}^∞ et $h^{(k)}(t) = (iX)^k e^{itX}$ donc $|h^{(k)}(t)| \leq |X^k|$ et le théorème de dérivation s'applique. \square

Application : – Si $X \sim \text{Geom}(p)$ alors

$$\varphi'_X(t) = \frac{ipe^{it}}{(1 - e^{it(1-p)})^2}$$

et $\varphi'_X(0) = \frac{i}{p}$ d'où $\mathbb{E}[X] = \frac{1}{p}$.

Théorème 4.5 (*Inversion de Fourier*)

Soit X une variable aléatoire de fonction caractéristique φ_X . Si φ_X est intégrable par rapport à la mesure de Lebesgue sur \mathbb{R}^d alors la loi \mathbb{P}_X de X admet une densité (par rapport à la mesure de Lebesgue).

▷ En dimension 1, soit $g \in \mathcal{C}_c^0(\mathbb{R})$. On a vu que

$$\begin{aligned} \mathbb{E}[g(X)] &= \frac{1}{2\pi} \lim_{\lambda \rightarrow 0} \int_{\mathbb{R}} \int_{\mathbb{R}} g(s) \varphi_X(t) e^{-ist} e^{-\lambda|t|} dt ds \\ &= \int_{\mathbb{R}} g(s) \left(\frac{1}{2\pi} \int_{\mathbb{R}} \varphi_X(t) e^{-ist} dt \right) ds \end{aligned}$$

par les théorèmes de Fubini et de convergence dominée qui s'appliquent car :

$$|g(s) \varphi_X(t) e^{-ist} e^{-\lambda|t|}| \leq |g(s)| |\varphi_X(t)| \in L^1(\mathbb{R}^2, ds \otimes dt).$$

\square

4.3 Autres fonctionnelles caractérisant la loi

4.3.1 Fonction génératrice pour des variables aléatoires entières

Soit X une variable aléatoires à valeurs dans \mathbb{N} . On note, pour $n \in \mathbb{N}$, $p_n = \mathbb{P}(X = n)$.

Définition 4.6

La fonction génératrice de X est définie par

$$M_X(t) = \mathbb{E}[t^X] = \sum_{n=0}^{+\infty} t^n p_n.$$

Propriétés 4.7

- M_X est bien définie sur $[0, 1]$.
- M_X est continue sur $[0, 1]$.
- M_X étant une série entière, M_X est \mathcal{C}^∞ sur $[0, 1[$.
- On a :

$$\forall n \in \mathbb{N}, \quad M_X((n))(0) = n!p_n$$

Conséquence : On retrouve facilement la loi de X à partir de M_X .

Exemples : – Si $X \sim \mathcal{B}(p)$, $\mathbb{P}(X = 0) = 1 - p$, $\mathbb{P}(X = 1) = p$.

$$M_X(t) = 1 - p + p^t.$$

- Si $X \sim \text{Geom}(p)$, $\forall n \geq 1$, $\mathbb{P}(X = n) = (1 - p)^{n-1}p$.

$$M_X(t) = \sum_{n=1}^{+\infty} t^n (1 - p)^{n-1} p = tp \sum_{n=1}^{+\infty} [t(1 - p)]^{n-1} = \frac{tp}{1 - t(1 - p)} \quad \text{si } t < \frac{1}{1 - p}.$$

4.3.2 Transformée de Laplace**Définition 4.8**

Soit X un vecteur aléatoire de \mathbb{R}^d . On définit la transformée de Laplace de X comme :

$$\begin{aligned} L_X(t) &= \mathbb{E}[e^{tX}] & \text{si } d = 1 \\ L_X(t) &= \mathbb{E}[e^{\langle t, X \rangle}] & \text{avec } t \in \mathbb{R}^d. \end{aligned}$$

De manière générale, on peut seulement dire que L_X est définie en 0.

Propriétés 4.9

- Si X est positive, s'il existe $t \neq 0$ tel que $L_X(t) < +\infty$ alors X admet des moments finis de tout ordres.
- S'il existe $t > 0$ tel que $L_{|X|}(t) < +\infty$ alors X admet des moments finis de tout ordres.
- S'il existe un voisinage V de 0 tel que $\forall t \in V$, $L_X(t) < +\infty$ alors X admet des moments finis de tout ordres.

Dans tous les cas précédents,

$$L_X^{(p)}(0) = \mathbb{E}[X^p].$$

- Si L_X est définie sur un voisinage de 0, alors L_X caractérise la loi.

Remarque : Si X est positive, L_X est définie sur \mathbb{R}_+ .

Chapitre 5

Notion d'indépendance en probabilités

On se place sur $(\Omega, \mathcal{F}, \mathbb{P})$ un espace de probabilités.

5.1 Définitions

Définition 5.1 (*Indépendance entre des événements*)

Deux événements $A, B \in \mathcal{F}$ sont dits indépendants si

$$\mathbb{P}(A \cap B) = \mathbb{P}(A)\mathbb{P}(B).$$

Une famille d'événements $(A_i)_{i \in I}$ est dite (mutuellement) indépendante si

$$\forall p \geq 2, \forall i_1, \dots, i_p \in I, \quad \mathbb{P}(A_{i_1} \cap \dots \cap A_{i_p}) = \mathbb{P}(A_{i_1})\mathbb{P}(A_{i_2}) \dots \mathbb{P}(A_{i_p}).$$

⚠ Les notions d'événements indépendants et d'événements disjoints sont deux notions bien distinctes. Si A et B sont disjoints $A \cap B = \emptyset$ donc A et B ne sont pas indépendants sauf si l'un est de probabilité nulle.

⚠ Mutuellement indépendants \implies indépendants deux à deux mais la réciproque est fausse. exemple : un joueur joue à Pile ou face. Il gagne 1 euro si Pile et perd 1 euro si Face.

$$A = \{\text{le joueur gagne 1 euro au 1}^{\text{er}} \text{ lancer}\}$$

$$B = \{\text{le joueur gagne 1 euro au 2}^{\text{e}} \text{ lancer}\}$$

$$C = \{\text{le joueur gagne 2 euros ou perd 2 euros lors des deux premiers lancers}\}$$

On a :

$$\mathbb{P}(A) = \frac{1}{2}, \quad \mathbb{P}(B) = \frac{1}{2}$$

et A et B sont indépendants. Comme $A \cap B$ et $A^c \cap B^c$ sont disjoints et A, B sont indépendants,

$$\mathbb{P}(C) = \mathbb{P}((A \cap B) \cup (A^c \cap B^c)) = \mathbb{P}(A \cap B) + \mathbb{P}(A^c \cap B^c) = \frac{1}{4} + \frac{1}{4} = \frac{1}{2}.$$

$$\mathbb{P}(A \cap C) = \mathbb{P}(A \cap B) = \frac{1}{4} = \mathbb{P}(A)\mathbb{P}(C)$$

donc A et C sont indépendants. De même, B et C sont indépendants. Mais

$$\mathbb{P}(A \cap B \cap C) = \mathbb{P}(A \cap B) = \frac{1}{4} \neq \mathbb{P}(A)\mathbb{P}(B)\mathbb{P}(C)$$

donc A, B, C ne sont pas mutuellement indépendants.

Remarque : Si A et B sont indépendants, alors A^c et B , A^c et B^c , A et B^c sont respectivement indépendants.

Définition 5.2 (*Indépendance pour des tribus*)

Soit \mathcal{F}_1 et \mathcal{F}_2 deux familles (en particulier tribus) d'ensembles mesurables. \mathcal{F}_1 et \mathcal{F}_2 sont indépendantes si pour tout $A_1 \in \mathcal{F}_1$ et tout $A_2 \in \mathcal{F}_2$, A_1 et A_2 sont indépendantes, ie.

$$\forall A_1 \in \mathcal{F}_1, \forall A_2 \in \mathcal{F}_2, \quad \mathbb{P}(A_1 \cap A_2) = \mathbb{P}(A_1)\mathbb{P}(A_2).$$

Une famille $(\mathcal{F}_i)_{i \in I}$ de sous-ensembles de \mathcal{F} est dite indépendante si

$$(A_i)_{i \in I} \text{ est mutuellement indépendante avec } \forall i \in I, A_i \in \mathcal{F}_i.$$

Proposition 5.3

Si \mathcal{A}_1 et \mathcal{A}_2 sont deux sous-ensembles de \mathcal{F} stables par intersection finie et indépendants, alors $\sigma(\mathcal{A}_1)$ et $\sigma(\mathcal{A}_2)$ sont indépendantes.

▷ Soit $A_1 \in \mathcal{A}_1$. Notons

$$\mathcal{M}_1 = \{A_2 \in \sigma(\mathcal{A}_2), A_1 \text{ et } A_2, \text{ sont indépendants}\}$$

On a $\Omega \in \mathcal{M}_1$, \mathcal{M}_1 est stable par différence, \mathcal{M}_1 est stable par union croissante, $\mathcal{A}_2 \subset \mathcal{M}_1$. Donc par le théorème des classes monotones, comme \mathcal{A}_2 est stable par intersection finie, $\mathcal{M}_1 = \sigma(\mathcal{A}_2)$. Soit $A_2 \in \sigma(\mathcal{A}_2)$. On pose

$$\mathcal{M}_2 = \{A_1 \in \sigma(\mathcal{A}_1), A_1 \text{ et } A_2 \text{ sont indépendants}\}.$$

On a montré que $\mathcal{A}_1 \subset \mathcal{M}_2$ donc, comme précédemment, par le théorème des classes monotones, $\mathcal{M}_2 = \sigma(\mathcal{A}_1)$, $\forall A_2 \in \sigma(\mathcal{A}_2)$. Donc $\sigma(\mathcal{A}_1)$ et $\sigma(\mathcal{A}_2)$ sont indépendantes. \square

Proposition 5.4

Si $(\mathcal{A}_i)_{i \in I}$ est une famille de sous-ensembles de \mathcal{F} indépendants et stables par intersections finie alors $(\sigma(\mathcal{A}_i))_{i \in I}$ est une famille de tribus indépendantes.

Proposition 5.5

Si $(\mathcal{F}_i)_{i \in I}$ sont des tribus indépendantes, si $I = \bigcup_{k \in K} I_k$ est une partition de I , alors, en notant,

pour $k \in K$, $\mathcal{G}_k = \sigma\left(\bigcup_{i \in I_k} \mathcal{F}_i\right)$, $(\mathcal{G}_k)_{k \in K}$ est indépendante.

Rappel : Soit X une variable aléatoire réelle. La tribu engendrée par X est

$$\sigma(X) = \{X^{-1}(A), A \in \mathcal{B}(\mathbb{R})\}.$$

$\sigma(X)$ est la plus petite tribu qui rend mesurable l'application $X : \Omega \rightarrow (\mathbb{R}, \mathcal{B}(\mathbb{R}))$. $\sigma(X)$ est la tribu qui contient toutes les informations liées à la variable X .

Définition 5.6

Deux variables aléatoires X et Y sont dites indépendantes si $\sigma(X)$ et $\sigma(Y)$ sont indépendantes, i.e.

$$\forall A, B \in \mathcal{B}(\mathbb{R}), \quad \mathbb{P}(X \in A, Y \in B) = \mathbb{P}(X \in A)\mathbb{P}(Y \in B)$$

Une famille de variables aléatoires $(X_i)_{i \in I}$ est (mutuellement) indépendante si les tribus associées sont indépendantes, i.e.

$$\forall p \geq 2, \forall i_1, \dots, i_p \in I, \forall A_{i_1}, \dots, A_{i_p} \in \mathcal{B}(\mathbb{R}), \quad \mathbb{P}(X_{i_1} \in A_{i_1}, \dots, X_{i_p} \in A_{i_p}) = \prod_{k=1}^p \mathbb{P}(X_{i_k} \in A_{i_k}).$$

Remarque : (X_1, \dots, X_d) est mutuellement indépendante si et seulement si $\forall A_1, \dots, A_d \in \mathcal{B}(\mathbb{R})$,

$$\mathbb{P}(X_1 \in A_1, \dots, X_d \in A_d) = \prod_{k=1}^d \mathbb{P}(X_k \in A_k).$$

5.2 Propriétés

Proposition 5.7

Soit $X = (X_1, \dots, X_d)$ un vecteur aléatoire. (X_1, \dots, X_d) est indépendante si et seulement si

$$\mathbb{P}_X = \mathbb{P}_{X_1} \otimes \dots \otimes \mathbb{P}_{X_d}.$$

▷ \Rightarrow : Supposons l'indépendance. Soit $A = A_1 \times \dots \times A_d \in \mathcal{B}(\mathbb{R})^d$.

$$\mathbb{P}_X(A) = \mathbb{P}(X \in A) = \mathbb{P}(X_1 \in A_1, \dots, X_d \in A_d) = \prod_{k=1}^d \mathbb{P}(X_k \in A_k) = \mathbb{P}_{X_1} \otimes \dots \otimes \mathbb{P}_{X_d}(A).$$

Comme les pavés engendrent $\mathcal{B}(\mathbb{R}^d)$ et forment une famille stable par intersection finie, on a

$$\mathbb{P}_X = \mathbb{P}_{X_1} \otimes \dots \otimes \mathbb{P}_{X_d}$$

\Leftarrow : Idem. □

Remarque : Si $X = (X_1, \dots, X_d)$ est mutuellement indépendant alors la connaissance des lois marginales suffit pour connaître la loi du vecteur.

Corollaire 5.8

Les assertions suivantes sont équivalentes :

- X_1, \dots, X_d d variables aléatoires sont indépendantes.
- $\mathbb{P}_{(X_1, \dots, X_d)} = \mathbb{P}_{X_1} \otimes \dots \otimes \mathbb{P}_{X_d}$.
- $\forall A_1, \dots, A_d \in \mathcal{B}(\mathbb{R}), \mathbb{P}(X_1 \in A_1, \dots, X_d \in A_d) = \prod_{i=1}^d \mathbb{P}(X_i \in A_i)$.
- $F_X(x) = \prod_{i=1}^d F_{X_i}(x_i)$ où $\forall x = (x_1, \dots, x_d) \in \mathbb{R}^d, F_X(x) = \mathbb{P}(X_1 \leq x_1, \dots, X_d \leq x_d)$.
- $\mathbb{E}[h_1(X_1) \dots h_d(X_d)] = \prod_{i=1}^d \mathbb{E}[h_i(X_i)]$ pour toute fonction h_i mesurable bornée ou positive ou telle que $h_i(X_i) \in L^1$.
- $\forall t = (t_1, \dots, t_d) \in \mathbb{R}^d, \varphi_X(t) = \prod_{i=1}^d \varphi_{X_i}(t_i)$ où $\varphi_X(t) = \mathbb{E}[e^{i\langle t, X \rangle}]$.
- (cas discret) $\mathbb{P}(X_1 = x_1, \dots, X_d = x_d) = \prod_{i=1}^d \mathbb{P}(X_i = x_i) \forall x_1, \dots, x_d$.
- (cas discret à valeurs dans \mathbb{N}^d) $M_X(t) = \prod_{i=1}^d M_{X_i}(t_i) \forall t \in [0, 1]^d$ où $M_X(t) = \mathbb{E}[t_1^{X_1} \dots t_d^{X_d}]$.
- $L_X(t) = \mathbb{E}[e^{t \cdot X}]$. Si L_X est définie sur un voisinage V de 0, $L_X(t) = \prod_{i=1}^d L_{X_i}(t_i), \forall t \in V$.
- (cas à densité) $f_{(X_1, \dots, X_d)}(x_1, \dots, x_d) = f_{X_1}(x_1) \dots f_{X_d}(x_d)$.

▷ – Fonction de répartition : Supposons que $\forall x \in \mathbb{R}^d, F_X(x) = \prod_{i=1}^d F_{X_i}(x_i)$. On note

$$\mathcal{D} = \{B =]-\infty, x_1] \times \dots \times]-\infty, x_d], (x_1, \dots, x_d) \in \mathbb{R}^d\}$$

\mathcal{D} est stable par intersection finie et \mathcal{D} engendre $\mathcal{B}(\mathbb{R}^d)$. On conclut par le théorème des classes monotones que X_1, \dots, X_d sont indépendantes.

Supposons que X_1, \dots, X_d sont indépendantes, il suffit de prendre $A_1 =]-\infty, x_1], \dots, A_d =]-\infty, x_d]$.

– Espérance : \Leftarrow Il suffit de prendre $h_i = \mathbf{1}_{A_i}$.

\Rightarrow Soient h_i comme voulue. Par le théorème de transfert,

$$\mathbb{E}[h_1(X_1) \dots h_d(X_d)] = \int_{\mathbb{R}^d} h_1(x_1) \dots h_d(x_d) d\mathbb{P}_{(X_1, \dots, X_d)}(x_1, \dots, x_d).$$

Par indépendance,

$$\begin{aligned} \mathbb{E}[h_1(X_1) \dots h_d(X_d)] &= \int_{\mathbb{R}^d} h_1(x_1) \dots h_d(x_d) \mathbb{P}_{X_1}(dx_1) \dots \mathbb{P}_{X_d}(dx_d) \\ &= \int_{\mathbb{R}} h_1(x_1) \mathbb{P}_{X_1}(dx_1) \times \dots \times \int_{\mathbb{R}} h_d(x_d) \mathbb{P}_{X_d}(dx_d) \text{ par le théorème de Fubini} \\ &= \mathbb{E}[h_1(X_1)] \dots \mathbb{E}[h_d(X_d)] \text{ par le théorème de transfert} \end{aligned}$$

Le reste en découle. □

Exemples : – Dans le cas discret. Soient X, Y deux variables aléatoires à valeurs finies discrètes, X et Y sont indépendantes si et seulement si $\forall x, y \mathbb{P}(X = x, Y = y) = \mathbb{P}(X = x)\mathbb{P}(Y = y)$.
On jette deux dés.

X = le nombre de chiffres pairs

Y = le maximum des deux chiffres

X et Y ne sont pas indépendantes car $\mathbb{P}(X = 0, Y = 6) = 0$ mais $\mathbb{P}(X = 0) = \frac{1}{4} > 0$ et $\mathbb{P}(Y = 6) = \frac{11}{36} > 0$.

– Soit (X, Y) un vecteur de densité $f_{(X,Y)}(x, y) = \frac{1}{3}\mathbf{1}_{[0,1] \times [-1,2]}(x, y) = \frac{1}{3}\mathbf{1}_{[0,1]}(x)\mathbf{1}_{[-1,2]}(y)$ on peut séparer les variables donc il y a indépendance.

$$f_{(X,Y)}(x, y) = \underbrace{\mathbf{1}_{[0,1]}(x)}_{=f_X(x)} \times \underbrace{\frac{1}{3}\mathbf{1}_{[-1,2]}(y)}_{=f_Y(y)}.$$

– Soit (X, Y) un vecteur de densité $f_{(X,Y)}(x, y) = \frac{1}{3\pi}e^{-\frac{x^2+2xy+5y^2}{6}}$: on ne peut pas séparer les variables, X et Y ne sont pas indépendantes.

$$\begin{aligned} f_X(x) &= \frac{1}{3}e^{-\frac{x^2}{6}} \int_{\mathbb{R}} e^{-\frac{2xy+5y^2}{6}} dy = \frac{1}{3\pi}e^{-\frac{x^2}{6}} \int_{\mathbb{R}} e^{-\frac{5(y+\frac{x}{5})^2}{6}} e^{\frac{x^2}{30}} dy \\ &= \frac{1}{3\pi}e^{-\frac{2x^2}{15}} \underbrace{\int_{\mathbb{R}} e^{-\frac{5(y+\frac{x}{5})^2}{6}} \frac{dy}{\sqrt{2\pi\sigma}}}_{\sigma^2=\frac{3}{5}, \text{ intégrale de la densité de } \mathcal{N}(-\frac{x}{5}, \frac{3}{5})} \times \sqrt{2\pi}\sigma = \frac{1}{\sqrt{2\pi}} \frac{2}{\sqrt{15}} e^{-\frac{2x^2}{15}} \end{aligned}$$

donc $X \sim \mathcal{N}(0, \frac{15}{4})$.

$$\begin{aligned} f_Y(y) &= \frac{1}{3\pi}e^{-\frac{5y^2}{6}} \int_{\mathbb{R}} e^{-\frac{x^2+2xy}{6}} dx = \frac{1}{3\pi}e^{-\frac{5y^2}{6}} \int_{\mathbb{R}} e^{-\frac{(x+y)^2}{6}} e^{\frac{y^2}{6}} dx \\ &= \frac{1}{3\pi}e^{-\frac{2y^2}{3}} \left(\int_{\mathbb{R}} e^{-\frac{(x+y)^2}{6}} \frac{dx}{\sqrt{2\pi\sqrt{3}}} \right) \times \sqrt{6\pi} = \sqrt{\frac{2}{3\pi}} e^{-\frac{2y^2}{3}} \end{aligned}$$

donc $Y \sim \mathcal{N}(0, \frac{3}{4})$.

$$f_X(x)f_Y(y) = \frac{2}{3\pi\sqrt{5}}e^{-\frac{2x^2}{15}}e^{-\frac{2y^2}{3}} \neq f_{(X,Y)}(x, y)$$

donc X et Y ne sont pas indépendants.

– (X, Y) vecteur de densité

$$f_{(X,Y)}(x, y) = \begin{cases} \sqrt{\frac{x}{y}} & \text{si } 0 < y \leq x < 1 \\ 0 & \text{sinon} \end{cases}$$

Au vu du domaine de $f_{(X,Y)}$ on remarque que $Y \leq X$: les variables sont dépendantes. Vérifier que $f_{(X,Y)}(x, y) \neq f_X(x)f_Y(y)$.

Proposition 5.9

| Soit $(X_i)_{i \in I}$ une famille de variables aléatoires. Les assertions suivantes sont équivalentes :

- $(X_i)_{i \in I}$ est indépendante.
- $\forall J \subset I$ partie finie de I , $(X_i)_{i \in J}$ est indépendante.
- $\forall J \subset I$, partie finie de I , $\mathbb{E} \left[\prod_{j \in J} h_j(X_j) \right] = \prod_{j \in J} \mathbb{E}[h_j(X_j)]$ pour toute h_j borélienne telle que $h_j(X_j) \in L^1$.

Remarque : Si X_1, \dots, X_d sont indépendantes alors

$$\mathbb{E}[X_1, \dots, X_d] = \prod_{i=1}^d \mathbb{E}[X_i].$$

La réciproque est fautive : $X_1 \sim \mathcal{U}[-1, 1]$, $X_2 = X_1^2$ $\mathbb{E}[X_1 X_2] = \mathbb{E}[X_1^3] = 0 = \underbrace{\mathbb{E}[X_1] \mathbb{E}[X_2]}_{=0}$ mais X_1 et X_2 ne sont pas indépendantes :

$$\mathbb{P} \left(|X_1| \leq \frac{1}{2}, X_2 > \frac{1}{2} \right) = 0 \neq \underbrace{\mathbb{P} \left(|X_1| \leq \frac{1}{2} \right) \mathbb{P} \left(X_2 > \frac{1}{2} \right)}_{>0}.$$

5.3 Corrélation et indépendance

Rappel : Soient X et Y deux variables aléatoires dans L^2 .

$$\text{cov}(X, Y) = \mathbb{E}[(X - \mathbb{E}[X])(Y - \mathbb{E}[Y])] = \mathbb{E}[XY] - \mathbb{E}[X]\mathbb{E}[Y]$$

Définition 5.10

X et Y deux variables aléatoires dans L^2 sont dites non corrélées si $\text{cov}(X, Y) = 0$.

Remarque : X, Y non corrélées si et seulement si $\langle X - \mathbb{E}[X], Y - \mathbb{E}[Y] \rangle = 0$ donc $X - \mathbb{E}[X]$ et $Y - \mathbb{E}[Y]$ sont orthogonaux pour le produit scalaire de L^2 .

Remarque : Si X et Y sont indépendantes alors X et Y sont non corrélées. La réciproque est fautive (en général).

Propriété 5.11

Si X et Y non corrélées alors $\text{Var}(X + Y) = \text{Var}(X) + \text{Var}(Y)$.

▷ $\text{Var}(X + Y) = \text{Var}(X) + \text{Var}(Y) + 2 \text{cov}(X, Y)$. □

Propriété 5.12

Si X_1, \dots, X_d sont deux à deux non corrélées, alors

$$\text{Var} \left(\sum_{i=1}^d X_i \right) = \sum_{i=1}^d \text{Var}(X_i)$$

▷ $\text{Var} \left(\sum_{i=1}^d \right) = \text{cov} \left(\sum_{i=1}^d X_i, \sum_{j=1}^d X_j \right) = \sum_{i,j} \text{cov}(X_i, X_j)$ car cov est une fonction bilinéaire. Donc

$$\text{Var} \left(\sum_{i=1}^d X_i \right) = \sum_{i=1}^d \text{Var}(X_i) + \sum_{i \neq j} \text{cov}(X_i, X_j) = \sum_{i=1}^d \text{Var}(X_i).$$

□

5.4 Événements asymptotiques

Soit $(\Omega, \mathcal{F}, \mathbb{P})$ un espace de probabilité.

5.4.1 Tribu du futur et tribu asymptotique

Définition 5.13

Soit $(\mathcal{F}_n)_{n \in \mathbb{N}}$ une suite de sous-tribus de \mathcal{F} . La tribu du futur est définie par

$$\mathcal{F}^n = \sigma \left(\bigcup_{k \geq n} \mathcal{F}_k \right)$$

La tribu asymptotique est définie par

$$\mathcal{F}^\infty = \bigcap_{n \geq 1} \mathcal{F}^n.$$

Exemple : On considère une suite $(X_n)_{n \geq 1}$ de variables aléatoires (on joue à pile ou face, X_n est le résultat du n -ième lancer).

$$\mathcal{F}_n = \sigma(X_1, \dots, X_n)$$

tribu engendrée par les n premières variables. \mathcal{F}_n représente l'ensemble des événements avant le n -ième lancer. \mathcal{F}_n est "l'histoire avant l'instant n ". Ici $\mathcal{F}_n \subset \mathcal{F}_{n+1}$.

$$\mathcal{F}^n = \sigma \left(\bigcup_{k \geq n} \mathcal{F}_k \right) = \sigma(\{X_k, k \geq n\})$$

\mathcal{F}^n représente les résultats après l'instant n , \mathcal{F}^n est "le futur après l'instant n ".

Exemple : $(X_n)_{n \geq 1}$ une suite de variables aléatoires. On définit $\mathcal{F}_n = \sigma(X_n)$. On suppose $\mathcal{F}_n \neq \mathcal{F}_k$ si $n \neq k$.

$$A = \{(X_n) \text{ passe une infinité de fois par } 0\} = \{\forall n \geq 1, \exists k \geq n, X_k = 0\} = \bigcap_{n \geq 1} \bigcup_{k \geq n} \{X_k = 0\}$$

donc $A = \limsup_n \{X_n = 0\}$. Comme $\forall n \geq 1, \bigcup_{k \geq n} \{X_k = 0\} \in \mathcal{F}^n$ donc $A \in \mathcal{F}^\infty$.

$$B = \{(X_n)_{n \in \mathbb{N}} \text{ est bornée par } M = \{\forall n \geq 1, |X_n| \leq M\} = \bigcap_{n \geq 1} \{|X_n| \leq M\} \notin \mathcal{F}^\infty$$

car $\{|X_1| \leq M\} \notin \mathcal{F}^n, \forall n \geq 2$.

$$\begin{aligned} C &= \{\text{la suite } (X_n)_{n \geq 1} \text{ converge}\} = \{\text{la suite } (X_{n+q})_{n \geq 1} \text{ converge}\} \\ &= \bigcap_{\varepsilon \in \mathbb{Q}^*} \bigcup_{N \geq q} \bigcap_{\substack{n \geq N \\ p \geq 0}} \{|X_n - X_{n+p}| < \varepsilon\} \in \mathcal{F}^q \end{aligned}$$

donc $C \in \mathcal{F}^q$ pour tout $q \geq 1$ donc $C \in \mathcal{F}^\infty$.

Théorème 5.14 (Loi du 0-1 de Kolmogorov)

Soit $(\mathcal{F}_n)_{n \geq 1}$ une suite de tribu indépendantes. Alors la tribu asymptotique est triviale

$$\forall A \in \mathcal{F}^\infty, \quad \mathbb{P}(A) = 0 \text{ ou } 1$$

Exemple : (X_n) suite de variables indépendantes $\mathcal{F}_n = \sigma(X_n)$. On a (\mathcal{F}_n) indépendantes et donc $\mathbb{P}(C) = \mathbb{P}((X_n) \text{ converge}) = 0 \text{ ou } 1$.

▷ On va montrer que \mathcal{F}^∞ est indépendante d'elle même. En effet, si c'est le cas, pour $A, B \in \mathcal{F}^\infty$, $\mathbb{P}(A \cap B) = \mathbb{P}(A)\mathbb{P}(B)$. Par conséquent, si on prend $B = A$, $\mathbb{P}(A) = \mathbb{P}(A)^2$ donc $\mathbb{P}(A) = 0 \text{ ou } 1$.

Par indépendance des tribus, \mathcal{F}^n est indépendante de $\sigma\left(\bigcup_{k < n} \mathcal{F}_k\right)$. Comme $\mathcal{F}^\infty \subset \mathcal{F}^n$, \mathcal{F}^∞ est

indépendant de $\sigma\left(\bigcup_{k < n} \mathcal{F}_k\right)$. Ceci est vrai pour tout $n \in \mathbb{N}$. Par conséquent, \mathcal{F}^∞ est indépendante

de $\mathcal{A} = \bigcup_{n \in \mathbb{N}} \sigma\left(\bigcup_{k < n} \mathcal{F}_k\right)$.

Montrons que \mathcal{A} est stable par intersection finie. Soient $A, B \in \mathcal{A}$. Il existe $n, m \geq 1$ tels que $A \in \sigma\left(\bigcup_{k < n} \mathcal{F}_k\right)$ et $B \in \sigma\left(\bigcup_{k < m} \mathcal{F}_k\right)$. Donc $A, B \in \sigma\left(\bigcup_{k < \max(n, m)} \mathcal{F}_k\right)$ qui est un tribu. Par

conséquent, $A \cap B \in \sigma\left(\bigcup_{k < \max(n, m)} \mathcal{F}_k\right)$ donc $A \cap B \in \mathcal{A}$.

Ainsi, \mathcal{F}^∞ est indépendante de \mathcal{A} , \mathcal{F}^∞ et \mathcal{A} sont stables par intersection finie, donc \mathcal{F}^∞ et $\sigma(\mathcal{A})$ sont indépendantes. On remarque que

$$\forall k \geq 1, \quad \mathcal{F}_k \subset \sigma(\mathcal{A})$$

donc

$$\mathcal{F}^\infty \subset \mathcal{F}^1 = \bigcup_{k \geq 1} \mathcal{F}_k \subset \sigma(\mathcal{A}).$$

Comme \mathcal{F}^∞ et $\sigma(\mathcal{A})$ sont indépendantes, \mathcal{F}^∞ est indépendante d'elle-même. □

Remarque : Si (\mathcal{F}_n) est une suite de tribus indépendantes, alors \mathcal{F}^∞ est triviale. Les variables aléatoires \mathcal{F}^∞ -mesurables sont donc les variables constantes presque sûrement.

5.4.2 Lemmes de Borel-Cantelli

Lemme 5.15 (*Borel-Cantelli 1*)

Soit $(A_n)_{n \geq 1}$ une suite d'événements telle que

$$\sum_{n \geq 1} \mathbb{P}(A_n) < \infty.$$

Alors

$$\mathbb{P}(\limsup_n A_n) = 0.$$

ie. seul un nombre fini de A_n est réalisé.

▷ La suite $\left(\bigcup_{k \geq n} A_k \right)_{n \geq 1}$ est une suite décroissante donc, comme $\limsup_n = \bigcap_{n \geq 1} \bigcup_{k \geq n} A_k$,

$$\mathbb{P}(\limsup_n) = \lim_n \mathbb{P} \left(\bigcup_{k \geq n} A_k \right) \leq \lim_{n \rightarrow +\infty} \sum_{k \geq n} \mathbb{P}(A_k) = 0 \quad (\text{reste d'une série convergente})$$

donc $\mathbb{P}(\limsup_n A_n) = 0$. □

Lemme 5.16 (*Borel-Cantelli 2*)

Soit $(A_n)_{n \geq 1}$ une suite d'événements indépendants telle que $\sum \mathbb{P}(A_n)$ diverge. Alors

$$\mathbb{P}(\limsup_n A_n) = 1.$$

ie. , presque sûrement, il y a une infinité d'événements A_n qui se réalise.

▷ $\mathbb{P}(\limsup_n A_n) = 1 - \mathbb{P}(\liminf_n A_n^c)$. Or $\mathbb{P}(\liminf_n A_n^c) = \mathbb{P} \left(\bigcup_{n \geq 1} \bigcap_{k \geq n} A_k^c \right)$. Or $\left(\bigcap_{k \geq n} A_k^c \right)$ est une suite croissante et $\left(\bigcap_{k=n}^m A_k^c \right)$ est une suite décroissante donc

$$\begin{aligned} \mathbb{P}(\liminf_n A_n^c) &= \lim_{n \rightarrow +\infty} \mathbb{P} \left(\bigcap_{k \geq n} A_k^c \right) = \lim_{n \rightarrow +\infty} \lim_{m \rightarrow +\infty} \mathbb{P} \left(\bigcap_{k=n}^m A_k^c \right) \\ &= \lim_{n \rightarrow +\infty} \lim_{m \rightarrow +\infty} \prod_{k=n}^m \mathbb{P}(A_k^c) = \lim_{n \rightarrow +\infty} \lim_{m \rightarrow +\infty} \prod_{k=n}^m \underbrace{(1 - \mathbb{P}(A_k))}_{\leq e^{-\mathbb{P}(A_k)}} \\ &= \lim_{n \rightarrow +\infty} \lim_{m \rightarrow +\infty} \exp \left(- \sum_{k=n}^m \mathbb{P}(A_k) \right) = 0 \end{aligned}$$

□

5.5 Probabilité conditionnelle

Rappel : A et B sont indépendants si et seulement si

$$\mathbb{P}(A \cap B) = \mathbb{P}(A)\mathbb{P}(B).$$

Que faire si A et B ne sont pas indépendants ?

Exemple : : On lance deux dés.

X = le nombre de chiffres pairs

Y = le maximum des deux chiffres

On prend

$$A = \{Y = 1\}$$

et

$$B = \{X = 2\}.$$

Sachant que B est réalisé, l'événement A est réalisé avec probabilité 0. Mais $\mathbb{P}(A) = \frac{1}{36} \neq 0$. La connaissance de B modifie la probabilité de réalisation de A .

Définition 5.17

Soient $A, B \in \mathcal{F}$ avec $\mathbb{P}(B) \neq 0$. On définit la probabilité de A sachant B , notée $\mathbb{P}(A|B)$, par

$$\mathbb{P}(A|B) = \frac{\mathbb{P}(A \cap B)}{\mathbb{P}(B)}.$$

Remarque : Si A et B sont indépendants,

$$\mathbb{P}(A|B) = \frac{\mathbb{P}(A \cap B)}{\mathbb{P}(B)} = \mathbb{P}(A).$$

Le fait de savoir que B est réalisé n'influence pas la probabilité de réalisation de A .

Propriété 5.18

L'application $\begin{array}{ll} \mathcal{F} & \rightarrow [0, 1] \\ A & \mapsto \mathbb{P}(A|B) \end{array}$ est une mesure de probabilité.

- ▷ – $\mathbb{P}(\Omega|B) = \frac{\mathbb{P}(B)}{\mathbb{P}(B)} = 1$.
– Soit $(A_i)_{i \in I}$ une suite d'événements disjoints.

$$\mathbb{P}\left(\bigcup_{i \in I} A_i | B\right) = \frac{\mathbb{P}\left(\left(\bigcup_{i \in I} A_i\right) | B\right)}{\mathbb{P}(B)} = \frac{\mathbb{P}\left(\bigcup_{i \in I} (A_i \cap B)\right)}{\mathbb{P}(B)} = \frac{\sum_{i \in I} \mathbb{P}(A_i \cap B)}{\mathbb{P}(B)} = \sum_{i \in I} \mathbb{P}(A_i | B).$$

□

Conséquences : – $\forall A \in \mathcal{F}, \mathbb{P}(A|B) = 1 - \mathbb{P}(A^c|B)$
 – si (A_i) est une suite croissante

$$\mathbb{P}\left(\bigcup A_i|B\right) = \lim \mathbb{P}(A_i|B).$$

etc.

$$\triangleq \mathbb{P}(A|B^c) \neq 1 - \mathbb{P}(A|B).$$

Formule des probabilités totales : Soient $A, B \in \mathcal{F}$ avec $\mathbb{P}(B) \neq 0$.

$$\mathbb{P}(A) = \mathbb{P}((A \cap B) \text{ ou } (A \cap B^c)) = \mathbb{P}(A \cap B) + \mathbb{P}(A \cap B^c) = \mathbb{P}(A|B)\mathbb{P}(B) + \mathbb{P}(A|B^c)\mathbb{P}(B^c)$$

donc

$$\mathbb{P}(A) = \mathbb{P}(A|B)\mathbb{P}(B) + \mathbb{P}(A|B^c)(1 - \mathbb{P}(B)).$$

De façon générale, si $(B_i)_{1 \leq i \leq n}$ est une partition de Ω , alors

$$\mathbb{P}(A) = \sum_{i=1}^n \mathbb{P}(A|B_i)\mathbb{P}(B_i)$$

Formule de Bayes : Soient $A, B \in \mathcal{F}$ avec $\mathbb{P}(A) \neq 0$ et $\mathbb{P}(B) \neq 0$.

$$\mathbb{P}(B|A) = \frac{\mathbb{P}(A|B)\mathbb{P}(B)}{\mathbb{P}(A|B)\mathbb{P}(B) + \mathbb{P}(A|B^c)(1 - \mathbb{P}(B))}.$$

Exemple : Une maladie affecte 0,5% de la population. Un test T permet de dépister la maladie avec la fiabilité suivantes.

- T est positif pour 95% des personnes malades,
- T est négatif pour 99% des personnes saines.

Quelle est la probabilité qu'un individu ayant un test positif soit malade ?

On veut calculer $\mathbb{P}(M|P)$. On sait que $\mathbb{P}(P|M) = 0,95$, $\mathbb{P}(P^c|M^c) = 0,99$ et $\mathbb{P}(M) = 0,005$. Par la formule de Bayes,

$$\mathbb{P}(M|P) = \frac{\mathbb{P}(P|M)\mathbb{P}(M)}{\mathbb{P}(P|M)\mathbb{P}(M) + \mathbb{P}(P|M^c)(1 - \mathbb{P}(M))} \approx 0,323.$$

Application : Loi conditionnelle.

Soit $B \in \mathcal{F}, \mathbb{P}(B) \neq 0$. Soit X une variable aléatoire. La loi conditionnelle de X sachant l'événement B est définie par $\mathbb{P}_X(\cdot|B)$, c'est-à-dire $\mathbb{P}(X \in A|B), \forall A \in \mathcal{B}(\mathbb{R})$.

L'espérance conditionnelle (si elle existe) de X sachant B , notée $\mathbb{E}[X|B]$ est l'espérance de la loi conditionnelle $\mathbb{P}_X(\cdot|B)$.

Dans le cas discret : si X est à valeurs dans $\{x_i\}$, il suffit de calculer $\mathbb{P}(X = x_i|B) \forall i \in I$ pour avoir $\mathbb{P}_X(\cdot|B)$.

Exemple : Soient N une variable aléatoire à valeurs dans \mathbb{N} , X_i des variables de loi $\mathcal{B}(p)$ avec $N, (X_i)_{i \in I}$ indépendants. On considère

$$S = \sum_{i=1}^N X_i.$$

Quelle est la loi de S sachant que $N = n$?

$\sum_{i=1}^n X_i \in \{0, \dots, n\}$ et $\mathbb{P}\left(\sum_{i=1}^n X_i = k\right) = \mathbb{P}(k \text{ variables parmi les } X_i \text{ sont égales à } 1) = \binom{n}{k} p^k (1-p)^{n-k}$. On a donc $\sum_{i=1}^n X_i \sim \mathcal{B}(n, p)$. Sachant que $N = n$, $S \sim \mathcal{B}(n, p)$. En effet, soit $k \geq 0$,

$$\begin{aligned} \mathbb{P}(S = k | N = n) &= \mathbb{P}\left(\sum_{i=1}^N X_i = K | N = n\right) \\ &= \begin{cases} 0 & \text{si } k > n \\ \mathbb{P}\left(\sum_{i=1}^n X_i = k | N = n\right) = \mathbb{P}\left(\sum_{i=1}^n X_i = k\right) = \binom{n}{k} p^k (1-p)^{n-k} & \text{si } k \leq n. \end{cases} \end{aligned}$$

Remarque : Si on connaît la loi de N , on peut en déduire la loi du couple (S, N) . Pour $k, n \in \mathbb{N}$,

$$\mathbb{P}(S = k, N = n) = \mathbb{P}(S = k | N = n) \mathbb{P}(N = n).$$

5.6 Somme de variables aléatoires indépendantes

Soient X et Y deux variables aléatoires indépendantes.

But : Trouver la loi \mathbb{P}_{X+Y} de $X + Y$.

On sait que (X, Y) a pour loi $\mathbb{P}_X \otimes \mathbb{P}_Y$. Par conséquent, la fonction de répartition de $X + Y$ est

$$F_{X+Y}(t) = \mathbb{P}(X + Y \leq t) = \iint_{\mathbb{R}^2} \mathbf{1}_{x+y \leq t} \mathbb{P}_X(dx) \mathbb{P}_Y(dy)$$

Par le théorème de Fubini-Tonelli,

$$F_{X+Y}(t) = \int_{\mathbb{R}} \left(\int_{-\infty}^{t-y} \mathbb{P}_X(dx) \right) \mathbb{P}_Y(dy) = \int_{\mathbb{R}} F_X(t-y) \mathbb{P}_Y(dy)$$

et de même

$$F_{X+Y}(t) = \int_{\mathbb{R}} F_Y(t-x) \mathbb{P}_X(dx).$$

On remarque que pour $A \in \mathcal{B}(\mathbb{R})$

$$\mathbb{P}(X + Y \in A) = \int \mathbf{1}_{x+y \in A} \mathbb{P}_X(dx) \mathbb{P}_Y(dy) = \int_{\mathbb{R}} \mathbb{P}_Y(A-x) \mathbb{P}_X(dx) = \int_{\mathbb{R}} \mathbb{P}_X(A-y) \mathbb{P}_Y(dy)$$

où $A-x = \{y-x, y \in A\}$.

5.6.1 Convolution de mesures

On considère (E, \mathcal{E}) un espace vectoriel mesuré.

Définition 5.19

Soient μ et ν deux mesures sur (E, \mathcal{E}) . On définit la convolée de μ avec ν , notée $\mu * \nu$, par

$$\forall A \in \mathcal{E}, \quad \mu * \nu(A) = \int_E \mu(A - x) \nu(dx)$$

Propriété 5.20

- $\mu * \nu$ est une mesure positive sur (E, \mathcal{E}) .
- $\mu * \nu = \nu * \mu$.
- Si μ et ν sont des mesures de probabilité alors $\mu * \nu$ est une mesure de probabilité.
- $\mu * \delta_0 = \mu$.
- Le produit de convolution est associatif.

- ▷ – $\mu * \nu(\emptyset) = 0$ car $\mu(\emptyset - x) = \mu(\emptyset) = 0$.
- (A_i) ensembles disjoints. Pour tout $x \in E$, les $(A_i - x)$ sont disjoints. En effet, si $z \in (A_i - x) \cap (A_j - x)$ alors $z = y_i - x = y_j - x$ donc $y_i = y_j$ donc $i = j$. Alors, par le théorème de convergence monotone,

$$\mu * \nu \left(\bigcup_{i \in I} A_i \right) = \int_E \sum_{i \in I} \mu(A_i - x) \nu(dx) = \sum_{i \in I} \int_E \mu(A_i - x) \nu(dx) = \sum_{i \in I} \mu * \nu(A_i).$$

Donc $\mu * \nu$ est bien une mesure.

- Si μ et ν sont des mesures de probabilité,

$$\mu * \nu(E) = \int_E \underbrace{\mu(E - x)}_{=E} \nu(dx) = \mu(E) \nu(E) = 1$$

donc $\mu * \nu$ est une mesure de probabilité.

- Par le théorème de Fubini-Tonelli

$$\mu * \nu(A) = \int_E \mu(A - x) \nu(dx) = \int_{E \times E} \mathbf{1}_{x+y \in A} \mu(dy) \nu(dx) = \nu * \mu(A).$$

$$- \mu * \delta_0(A) = \int_{E \times E} \mathbf{1}_{x+y \in A} \delta_0(dy) \mu(dx) = \int_E \mathbf{1}_{x \in A} \mu(dx) = \mu(A). \quad \square$$

Conséquences : – Si X et Y sont des variables aléatoires indépendantes alors $\mathbb{P}_{X+Y} = \mathbb{P}_X * \mathbb{P}_Y$.

- Si X_1, \dots, X_n sont (mutuellement) indépendantes alors

$$\mathbb{P}_{X_1 + \dots + X_n} = \mathbb{P}_{X_1} * \dots * \mathbb{P}_{X_n}.$$

- La fonction caractéristique de $\sum_{i=1}^n X_i$ est

$$\varphi_{X_1 + \dots + X_n} = \mathbb{E} [e^{it(X_1 + \dots + X_n)}] = \prod_{i=1}^n \varphi_{X_i}(t)$$

car les variables sont indépendantes.

5.6.2 Exemples

Cas discret : Soient X une variable aléatoire à valeurs dans $\{x_i\}_{i \in I}$ et Y une variable aléatoire à valeurs dans $\{y_j\}_{j \in J}$ telles que X et Y sont indépendantes. On définit $Z = X + Y$. Z est à valeurs dans $\{x_i + y_j, i \in I, j \in J\}$.

$$\mathbb{P}(Z = z) = \mathbb{P}(X + Y = z) = \sum_{i \in I} \mathbb{P}(Y = z - x_i) \mathbb{P}(X = x_i) = \sum_{j \in J} \mathbb{P}(X = z - y_j) \mathbb{P}(Y = y_j)$$

– Si X_1, \dots, X_n sont indépendantes de loi $\mathcal{B}(p)$ alors $S = X_1 + \dots + X_n$ suit la loi $\mathcal{B}(n, p)$

Conséquence : $\mathbb{E}[S] = \mathbb{E}[X_1] + \dots + \mathbb{E}[X_n] = np$ car l'espérance est linéaire. $\text{Var}(S) = \text{Var}(X_1) + \dots + \text{Var}(X_n) = np(1 - p)$ car les variables sont indépendantes.

Cas à densité

Proposition 5.21

Si X est une variable aléatoire de densité f_X , Y est une variable de densité f_Y et X et Y sont indépendantes alors $X + Y$ est une variable à densité de densité

$$f_{X+Y}(z) = \int_{\mathbb{R}} f_X(z - y) f_Y(y) dy = \int_{\mathbb{R}} f_Y(z - x) f_X(x) dx = f_X * f_Y(z).$$

▷ Soit $A \in \mathcal{B}(\mathbb{R})$

$$\mathbb{P}(X + Y \in A) = \int_{\mathbb{R}^2} \mathbf{1}_{x+y \in A} \mathbb{P}_X(dx) \mathbb{P}_Y(dy) = \int_{\mathbb{R}^2} \mathbf{1}_{x+y \in A} f_X(x) f_Y(y) dx dy$$

On pose $z = x + y$ et $t = x$. $x \in \mathbb{R}, y \in \mathbb{R}, x + y \in A \iff z \in A, t \in \mathbb{R}$ donc par changement de variables

$$\mathbb{P}(X + Y \in A) = \int_{A \times \mathbb{R}} f_X(t) f_Y(z - t) dz dt = \int_A \left(\int_{\mathbb{R}} f_X(t) f_Y(z - t) dt \right) dz.$$

□

Exemple : Soient $X \sim \mathcal{N}(m_X, \sigma_X^2)$ et $Y \sim \mathcal{N}(m_Y, \sigma_Y^2)$ des variables aléatoires indépendantes. Quelle est la loi de $X + Y$?

$$\varphi_{X+Y}(t) = \varphi_X(t) \varphi_Y(t) = e^{itm_X} e^{\frac{t^2 \sigma_X^2}{2}} e^{itm_Y} e^{\frac{t^2 \sigma_Y^2}{2}} = e^{it(m_X + m_Y)} e^{\frac{t^2}{2}(\sigma_X^2 + \sigma_Y^2)}$$

donc $X + Y \sim \mathcal{N}(m_X + m_Y, \sigma_X^2 + \sigma_Y^2)$.

Remarque : L'utilisation de la fonction caractéristique est en général bien utile pour trouver la loi d'une somme de variables aléatoires indépendantes.

Chapitre 6

Convergence d'une suite de variables aléatoires

6.1 Convergence trajectorielle

Soient $(\Omega, \mathcal{F}, \mathbb{P})$ un espace de probabilité, X une variable aléatoire et $(X_n)_{n \in \mathbb{N}}$ une suite de variable aléatoire sur $(\Omega, \mathcal{F}, \mathbb{P})$ à valeurs dans $(\mathbb{R}^d, \mathcal{B}(\mathbb{R}^d))$. \mathbb{R}^d est muni de la norme euclidienne $\|\cdot\|$.

6.1.1 Convergence presque sûre

Elle correspond à la convergence simple des suites de fonctions :

$$\forall \omega \in \Omega, \quad X_n(\omega) \xrightarrow[n \rightarrow +\infty]{} X(\omega) \quad (\text{convergence simple})$$

Cette notion est trop forte pour les probabilités.

Définition 6.1

La suite $(X_n)_{n \in \mathbb{N}}$ converge presque sûrement vers X s'il existe $N \in \mathcal{F}$ tel que $\mathbb{P}(N) = 0$ et $\forall \omega \in N, X_n(\omega) \xrightarrow[n \rightarrow +\infty]{} X(\omega)$.
On note alors $X_n \xrightarrow[n \rightarrow +\infty]{p.s.} X$.

Remarque : 1. $\{X_n \xrightarrow[n \rightarrow +\infty]{} X\} = \{\omega \in \Omega, X_n(\omega) \xrightarrow[n \rightarrow +\infty]{} X(\omega)\} = \bigcap_{p \in \mathbb{N}^*} \bigcup_{n \in \mathbb{N}} \bigcap_{k \geq n} \left\{ |X_n - X| < \frac{1}{p} \right\}$

donc $\{X_n \xrightarrow[n \rightarrow +\infty]{} X\} \in \mathcal{F}$. Ainsi,

$$X_n \xrightarrow[n \rightarrow +\infty]{p.s.} X \quad \Longleftrightarrow \quad \mathbb{P}(X_n \xrightarrow[n \rightarrow +\infty]{} X) = 1.$$

2. Si $X_n = (X_n^1, \dots, X_n^d)$

$$X_n \xrightarrow[n \rightarrow +\infty]{p.s.} X = (X^1, \dots, X^d) \quad \Longleftrightarrow \quad \forall i \in \{1, \dots, d\}, X_n^i \xrightarrow[n \rightarrow +\infty]{p.s.} X^i.$$

Proposition 6.2

$$X_n \xrightarrow[n \rightarrow +\infty]{p.s.} X \quad \Longleftrightarrow \quad \forall \varepsilon > 0, \mathbb{P}(\limsup\{|X_n - X| > \varepsilon\}) = 0$$

▷ \Rightarrow : Soit $\varepsilon > 0$. Soit $\omega \in \limsup\{|X_n - X| > \varepsilon\}$.

$$\forall n \geq 0, \exists k \geq n, \quad |X_k(\omega) - X(\omega)| > \varepsilon.$$

Il y a une infinité de k telle que $|X_k(\omega) - X(\omega)| > \varepsilon$. Donc $X_n(\Omega)$ ne converge pas vers $X(\Omega)$. Ainsi, $\Omega \in \{X_n \xrightarrow{n \rightarrow +\infty} X\}^c$. Ainsi, $\mathbb{P}(\limsup\{|X_n - X| > \varepsilon\}) \leq \mathbb{P}(\{X_n \xrightarrow{n \rightarrow +\infty} X\}^c) = 0$.

\Leftarrow : $N = \bigcup_{p \in \mathbb{N}^*} \limsup \left\{ |X_n - X| > \frac{1}{p} \right\}$ est réunion dénombrable d'ensembles négligeables donc $\mathbb{P}(N) = 0$. Si $\omega \notin N$ alors

$$\omega \in \bigcap_{p \in \mathbb{N}^*} \liminf \left\{ |X_n - X| \leq \frac{1}{p} \right\}$$

donc

$$\forall p \in \mathbb{N}^*, \exists n = n(\omega, p), \forall k \geq n, \quad |X_k(\omega) - X(\omega)| \leq \frac{1}{p}$$

ie. $X_n(\omega) \xrightarrow{n \rightarrow +\infty} X(\omega)$. Ainsi $X_n \xrightarrow{n \rightarrow +\infty} X$. □

Corollaire 6.3

Si $\forall \varepsilon > 0 \sum_{n \geq 0} \mathbb{P}(|X_n - X| > \varepsilon)$ converge alors $X_n \xrightarrow{n \rightarrow +\infty} X$.

▷ Soit $\varepsilon > 0$. Comme $\sum \mathbb{P}(|X_n - X| > \varepsilon)$ converge, par le premier lemme de Borel-Cantelli on a $\mathbb{P}(\limsup\{|X_n - X| > \varepsilon\}) = 0$ et on conclut par la proposition précédente. □

Proposition 6.4

Si les (X_n) sont mutuellement indépendantes, on a

$$X_n \xrightarrow{n \rightarrow +\infty} 0 \quad \Longleftrightarrow \quad \forall \varepsilon > 0, \sum_{n \geq 0} \mathbb{P}(|X_n| > \varepsilon) \text{ converge.}$$

▷ \Leftarrow : fait dans le corollaire précédent.

\Rightarrow : Posons $A_n = \{|X_n| > \varepsilon\}$. Les (A_n) sont des événements indépendants. Si $\sum_{n \geq 0} \mathbb{P}(A_n)$ diverge alors par le second lemme de Borel-Cantelli, $\mathbb{P}(\limsup A_n) = 1$ ce qui contredit la convergence presque sûre. Donc $\sum_{n \geq 0} \mathbb{P}(|X_n| > \varepsilon)$ converge. □

Lemme 6.5

Soit (ε_n) suite de réels positifs telle que $\sum_{n=0}^{\infty} \varepsilon_n < +\infty$. Si $\sum_{n \geq 0} \mathbb{P}(|X_{n+1} - X_n| > \varepsilon_n)$ est convergente alors (X_n) converge presque sûrement.

▷ $X_n = X_0 + \sum_{k=0}^{n-1} (X_{k+1} - X_k)$. Par le lemme de Borel-Cantelli, comme $\sum_{n \geq 0} \mathbb{P}(|X_{n+1} - X_n| > \varepsilon_n)$ converge, $\mathbb{P}(\limsup\{|X_{n+1} - X_n| > \varepsilon\}) = 0$. Soit $\omega \notin \limsup\{|X_{n+1} - X_n| > \varepsilon\}$. Il existe $n(\omega) \geq 0$

tel que $\forall k \geq n \quad |X_{k+1}(\omega) - X_k(\omega)| \leq \varepsilon_k$. Donc $\sum_{k \geq 0} |X_{k+1}(\omega) - X_k(\omega)|$ est convergente donc (X_n) converge. On a bien (X_n) converge presque sûrement. \square

Propriétés 6.6

- Si $X_n \xrightarrow[n \rightarrow +\infty]{p.s.} X$ et $X_n \xrightarrow[n \rightarrow +\infty]{p.s.} Y$ alors $X = Y$ presque sûrement.
 - Si $X_n \xrightarrow[n \rightarrow +\infty]{p.s.} X$ et $f : \mathbb{R}^d \rightarrow \mathbb{R}^d$ est continue alors $f(X_n) \xrightarrow[n \rightarrow +\infty]{p.s.} f(X)$.
 - Si $\forall n \in \mathbb{N}, X_n \stackrel{p.s.}{=} Y_n$,
- $$X_n \xrightarrow[n \rightarrow +\infty]{p.s.} X \iff Y_n \xrightarrow[n \rightarrow +\infty]{p.s.} Y.$$

6.1.2 Convergence dans L^p

L^p est l'espace quotient de \mathcal{L}^p (ensemble des variables aléatoires X telles que $|X|^p$ est intégrable) avec la relation d'équivalence $X \sim Y \Leftrightarrow X = Y$ p.s.

Définition 6.7

Soit (X_n) une suite de variables aléatoires de L^p . (X_n) converge vers X dans L^p (en moyenne d'ordre p) si $\mathbb{E}[|X_n - X|^p] \xrightarrow[n \rightarrow +\infty]{} 0$. On note $X_n \xrightarrow[n \rightarrow +\infty]{L^p} X$.

Proposition 6.8

Si (X_n) est une suite de variable de L^p telle que $X_n \xrightarrow[n \rightarrow +\infty]{L^p} X$ alors pour tout $q \leq p$, $X_n \xrightarrow[n \rightarrow +\infty]{L^q} X$.

▷ Par l'inégalité de Hölder,

$$\mathbb{E}[|X_n - X|^q] \leq \mathbb{E}[|X_n - X|^p]^{\frac{q}{p}} \xrightarrow[n \rightarrow +\infty]{} 0.$$

\square

Théorème 6.9 (de convergence dominée)

Soit (X_n) une suite de variables aléatoires telle que

- il existe une variable aléatoire Y positive dans L^p telle que $|X_n| \leq Y$ p.s
- $X_n \xrightarrow[n \rightarrow +\infty]{p.s.} X$.

Alors $X_n \in L^p$ et $X_n \xrightarrow[n \rightarrow +\infty]{L^p} X$.

Exemple : Soit (X_n) une suite de variables aléatoires de loi

$$\mathbb{P}(X_n = 0) = 1 - p_n \quad \mathbb{P}(X_n = x_n) = p_n$$

avec $p_n \in]0, 1[$ et $x_n \geq 1$.

Les (X_n) sont indépendantes donc $X_n \xrightarrow[n \rightarrow +\infty]{p.s.}$ si et seulement si pour tout $\varepsilon > 0 \sum_{n \geq 0} \mathbb{P}(|X_n| > \varepsilon)$

converge, *ie.* $\sum_{n \geq 0} p_n < \infty$.

(X_n) converge vers 0 dans L^p si et seulement si $\mathbb{E}[|X_n|^p] = x_n^p p_n \xrightarrow{n \rightarrow +\infty} 0$.

- Si $p_n = \frac{1}{n}$ et $x_n = 1$. Alors X_n ne converge pas ps mais X_n converge dans tous les L^p .
- Si $p_n = 2^{-n}$ et $x_n = 2^n$ alors $X_n \xrightarrow[n \rightarrow +\infty]{p.s.} 0$ mais X_n ne converge dans aucun L^p .
- Si $p_n = \frac{1}{n^2}$ et $x_n = n$ alors $X_n \xrightarrow[n \rightarrow +\infty]{L^1} 0$ mais ne converge pas dans L^2 .

6.1.3 Convergence en probabilité

Soient (X_n) une suite de variables aléatoires sur $(\Omega, \mathcal{F}, \mathbb{P})$ et X une variable aléatoire.

Définition 6.10

La suite (X_n) converge en probabilité vers X , noté $X_n \xrightarrow[n \rightarrow +\infty]{\mathbb{P}} X$, si

$$\forall \varepsilon > 0, \quad \lim_{n \rightarrow +\infty} \mathbb{P}(|X_n - X| > \varepsilon) = 0$$

ou encore

$$\forall \varepsilon > 0, \quad \lim_{n \rightarrow +\infty} \mathbb{P}(|X_n - X| < \varepsilon) = 1.$$

Propriété 6.11

X_n est à valeurs dans \mathbb{R}^d .

$$X_n = (X_n^1, \dots, X_n^d) \xrightarrow[n \rightarrow +\infty]{\mathbb{P}} X = (X^1, \dots, X^d) \iff \forall i \in \{1, \dots, d\}, \quad X_n^i \xrightarrow[n \rightarrow +\infty]{\mathbb{P}} X^i.$$

▷ On a

$$|X_n - X|^2 = \sum_{i=1}^d |X_n^i - X^i|^2.$$

\Rightarrow : $\forall i \in \{1, \dots, d\}, \mathbb{P}(|X_n^i - X^i| > \varepsilon) \leq \mathbb{P}(|X_n - X| > \varepsilon)$ d'où le résultat.

$$\Leftarrow : \mathbb{P}(|X_n - X| > \varepsilon) \leq \mathbb{P}\left(\bigcup_{i=1}^d \left\{|X_n^i - X^i| > \frac{\varepsilon}{\sqrt{d}}\right\}\right) \leq \sum_{i=1}^d \mathbb{P}\left(|X_n^i - X^i| > \frac{\varepsilon}{\sqrt{d}}\right) \xrightarrow[n \rightarrow +\infty]{} 0$$

d'où le résultat. \square

Remarque : Si $X_n \xrightarrow[n \rightarrow +\infty]{\mathbb{P}} X$ et $X_n \xrightarrow[n \rightarrow +\infty]{\mathbb{P}} Y$ alors $X = Y$ ps (unicité ps de la limite).

▷ Soit $\varepsilon > 0$,

$$\mathbb{P}(|X - Y| > \varepsilon) \leq \mathbb{P}\left(|X - X_n| > \frac{\varepsilon}{2}\right) + \mathbb{P}\left(|X_n - Y| > \frac{\varepsilon}{2}\right) \xrightarrow[n \rightarrow +\infty]{} 0$$

donc

$$\forall \varepsilon > 0, \quad \mathbb{P}(|X - Y| > \varepsilon) = 0$$

ie.

$$\mathbb{P}(X \neq Y) = \mathbb{P}\left(\bigcup_{k \geq 1} |X - Y| > \frac{1}{k}\right) = 0$$

ie. $X = Y$ ps. □

Proposition 6.12

Soit $f : \mathbb{R}^d \rightarrow \mathbb{R}^p$ continue. Si $X_n \xrightarrow[n \rightarrow +\infty]{\mathbb{P}} X$ alors $f(X_n) \xrightarrow[n \rightarrow +\infty]{\mathbb{P}} f(X)$.

Conséquence : Si $X_n \xrightarrow[n \rightarrow +\infty]{\mathbb{P}} X$, $Y_n \xrightarrow[n \rightarrow +\infty]{\mathbb{P}} Y$, $\alpha_n \in \mathbb{R}$ $\alpha_n \xrightarrow[n \rightarrow +\infty]{} \alpha$ alors $\alpha_n X_n + Y_n \xrightarrow[n \rightarrow +\infty]{\mathbb{P}} \alpha X + Y$.

Si $X_n, Y_n \in \mathbb{R}$, $X_n Y_n \xrightarrow[n \rightarrow +\infty]{\mathbb{P}} XY$.

▷ On utilise l'uniforme continuité de f sur les compacts. Soient $a > 0, \varepsilon > 0$. Il existe $\delta > 0$ tel que

$$\forall x, y \in \mathbb{R}^d, \quad |x| \leq a, |x - y| \leq \delta \implies |f(x) - f(y)| \leq \varepsilon.$$

donc

$$\{|X| \leq a\} \cap \{|X_n - X| \leq \delta\} \subset \{|f(X_n) - f(X)| \leq \varepsilon\}$$

d'où, par passage au complémentaire,

$$\{|f(X_n) - f(X)| > \varepsilon\} \subset \{|X| > a\} \cup \{|X_n - X| > \delta\}$$

donc

$$\mathbb{P}(|f(X_n) - f(X)| > \varepsilon) \leq \mathbb{P}(|X| > a) + \underbrace{\mathbb{P}(|X_n - X| > \delta)}_{\xrightarrow[n \rightarrow +\infty]{} 0}.$$

Alors,

$$\limsup_{n \rightarrow +\infty} \mathbb{P}(|f(X_n) - f(X)| > \varepsilon) \leq \mathbb{P}(|X| > a) \xrightarrow[a \rightarrow +\infty]{} 0$$

par le théorème de convergence monotone (car X est à valeurs dans \mathbb{R}^d). Ainsi, $\mathbb{P}(|f(X_n) - f(X)| > \varepsilon) \xrightarrow[n \rightarrow +\infty]{} 0$ pour tout $\varepsilon > 0$ donc $f(X_n) \xrightarrow[n \rightarrow +\infty]{\mathbb{P}} f(X)$. □

Proposition 6.13

Si $X_n \rightarrow X$ ps ou dans L^1 alors $X_n \xrightarrow[n \rightarrow +\infty]{\mathbb{P}} X$.

▷ (i) Supposons que $X_n \xrightarrow[n \rightarrow +\infty]{\text{p.s.}} X$. Soit $\varepsilon > 0$.

$$\mathbb{P}(|X_n - X| > \varepsilon) = \mathbb{E}[\mathbf{1}_{|X_n - X| > \varepsilon}].$$

Or $\mathbf{1}_{\{|X_n - X| > \varepsilon\}} \xrightarrow[n \rightarrow +\infty]{\text{p.s.}} 0$ car $X_n \xrightarrow[n \rightarrow +\infty]{\text{p.s.}} X$, $\mathbf{1}_{\{|X_n - X| > \varepsilon\}} \leq 1$ donc par le théorème de convergence dominée $\mathbb{P}(|X_n - X| > \varepsilon) \xrightarrow[n \rightarrow +\infty]{} 0$ pour tout ε ie. $X_n \xrightarrow[n \rightarrow +\infty]{\mathbb{P}} X$.

(ii) Supposons que $X_n \xrightarrow[n \rightarrow +\infty]{L^1} X$. Soit $\varepsilon > 0$. On sait que $\mathbb{E}[|X_n - X|] \xrightarrow[n \rightarrow +\infty]{} 0$. Par l'inégalité de Markov,

$$\mathbb{P}(|X_n - X| > \varepsilon) \leq \frac{\mathbb{E}[|X_n - X|]}{\varepsilon} \xrightarrow[n \rightarrow +\infty]{} 0$$

donc $X_n \xrightarrow[n \rightarrow +\infty]{\mathbb{P}} X$. □

Exemple : $X_n \sim \mathcal{B}(p_n)$ indépendantes, $X_n \in \{0, x_n\}$ avec $x_n \geq 1$. $X_n \xrightarrow[n \rightarrow +\infty]{\mathbb{P}} 0$ si $\forall \varepsilon > 0$, $\mathbb{P}(|X| > \varepsilon) \xrightarrow[n \rightarrow +\infty]{} 0$. Or $\varepsilon < 1$, $\mathbb{P}(|X_n| > \varepsilon) = p_n$. Prenons $p_n = \frac{1}{n}$. Alors $X_n \xrightarrow[n \rightarrow +\infty]{\mathbb{P}} 0$.

Avec $x_n = n$, X_n ne converge pas ps et X_n ne converge pas dans L^1 vers 0.

Proposition 6.14

Si (X_n) converge en probabilité vers X alors il existe une sous-suite (X_{n_k}) qui converge ps vers X .

▷ Rappel : si (ε_k) est une suite telle que $\sum \varepsilon_k < +\infty$ et $\sum \mathbb{P}(|X_{k+1} - X_k| > \varepsilon_k) < +\infty$ alors X_k converge ps.

Pour tout $k \geq 0$, en prenant $\varepsilon = 2^{-k-1}$,

$$\lim_{n \rightarrow +\infty} \mathbb{P}(|X_n - X| > 2^{-k-1}) = 0$$

donc il existe n_k tel que

$$\forall n \geq n_k, \quad \mathbb{P}(|X_n - X| > 2^{-k-1}) \leq 2^{-k-1} \quad (*).$$

On construit ainsi une suite (n_k) que l'on peut supposer croissante car $(*)$ est vraie pour n_k mais aussi pour $n_k + 1, \dots$. Prenons $\varepsilon_k = 2^{-k}$. On a bien $\sum \varepsilon_k < +\infty$ et

$$\mathbb{P}(|X_{n_{k+1}} - X_{n_k}| > 2^{-k}) \leq \mathbb{P}(|X_{n_{k+1}} - X| > 2^{-k-1}) + \mathbb{P}(|X_{n_k} - X| > 2^{-k-1}) \leq 2^{-k}$$

qui est le terme général d'une série convergente. Donc $(X_{n_k})_{k \geq 0}$ converge presque sûrement.

Soit Y la limite de (X_{n_k}) . $X_{n_k} \xrightarrow[n \rightarrow +\infty]{p.s.} Y$ donc $X_{n_k} \xrightarrow[n \rightarrow +\infty]{\mathbb{P}} Y$. Or (X_{n_k}) est une sous-suite de (X_n) donc $X_{n_k} \xrightarrow[n \rightarrow +\infty]{\mathbb{P}} X$. Donc $Y = X$ ps. \square

Remarque : $X_n \xrightarrow[n \rightarrow +\infty]{\mathbb{P}} X$ si et seulement si de toute sous-suite (X_{n_k}) on peut extraire une sous-suite qui converge ps.

6.1.4 Critères de convergence (de type Cauchy)

Proposition 6.15

Soit (X_n) une suite de variables aléatoires à valeurs dans \mathbb{R}^d .

(i) (X_n) converge ps si et seulement si $\forall \varepsilon > 0$, $\lim_{n \rightarrow +\infty} \mathbb{P}(\sup_{k \geq 0} |X_{n+k} - X_n| > \varepsilon) = 0$.

(ii) (X_n) converge en probabilité si et seulement si $\forall \varepsilon > 0$, $\lim_{n \rightarrow +\infty} \sup_{k \geq 0} \mathbb{P}(|X_{n+k} - X_n| > \varepsilon) = 0$.

(iii) $X_n \in L^p$. (X_n) converge dans L^p si et seulement si $\lim_{n \rightarrow +\infty} \sup_{k \geq 0} \mathbb{E}[|X_{n+k} - X_n|^p] = 0$.

▷ (iii) Il s'agit de la complétude de L^p .

(i) \Rightarrow : Supposons que (X_n) converge presque sûrement. Presque sûrement, (X_n) est une suite de Cauchy dans \mathbb{R}^d : $\sup_{k \geq 0} |X_{n+k} - X_n| \xrightarrow[n \rightarrow +\infty]{} 0$ presque sûrement et donc en probabilité.

\Leftarrow : On note $Y_n = \sup_{p,q \geq n} |X_p - X_q|$. Y_n est une suite décroissante minorée par 0 donc (Y_n) converge presque sûrement vers Y . Par ailleurs, $Y_n \leq 2 \sup_{k \geq 0} |X_{n+k} - X_n|$ car $|X_p - X_q| \leq |X_p - X_n| + |X_n - X_q|$. Comme $\sup_{k \geq 0} |X_{n+k} - X_n| \xrightarrow[n \rightarrow +\infty]{\mathbb{P}} 0$ et $Y_n \xrightarrow[n \rightarrow +\infty]{\text{p.s.}} Y$, $Y = 0$ ps. Ceci implique que (X_n) est de Cauchy ps et donc (X_n) converge ps (\mathbb{R}^d complet).

(ii) $\Rightarrow \mathbb{P}(|X_{n+k} - X_n| > \varepsilon) \leq \mathbb{P}(|X_{n+k} - X| > \frac{\varepsilon}{2}) + \mathbb{P}(|X_n - X| > \frac{\varepsilon}{2})$ donc

$$\sup_{k \geq 0} \mathbb{P}(|X_{n+k} - X_n| > \varepsilon) \leq 2 \sup_{k \geq 0} \mathbb{P}\left(|X_{n+k} - X| > \frac{\varepsilon}{2}\right).$$

Comme $\lim_{n \rightarrow +\infty} \mathbb{P}(|X_n - X| > \frac{\varepsilon}{2}) = 0$, on a

$$\lim_{n \rightarrow +\infty} \sup_{k \geq 0} \mathbb{P}\left(|X_{n+k} - X| > \frac{\varepsilon}{2}\right) = 0,$$

d'où le résultat.

\Leftarrow Il existe une sous-suite (X_{n_p}) telle que

$$\sup_{k \geq 0} \mathbb{P}(|X_{n_p+k} - X_{n_p}| > 2^{-p}) \leq 2^{-p}.$$

En particulier,

$$\mathbb{P}(|X_{n_p+1} - X_{n_p}| > 2^{-p}) \leq 2^{-p}$$

donc (X_{n_p}) converge ps. Soit X sa limite

$$\begin{aligned} \mathbb{P}(|X_n - X| > \varepsilon) &\leq \mathbb{P}(|X_n - X_{n_p}| > \frac{\varepsilon}{2}) + \mathbb{P}(|X_{n_p} - X| > \frac{\varepsilon}{2}) \\ &\leq \sup_{k \geq 0} \mathbb{P}(|X_n - X_{n+k}| > \frac{\varepsilon}{2}) + \mathbb{P}(|X_{n_p} - X| > \frac{\varepsilon}{2}) \xrightarrow[n \rightarrow +\infty]{} 0. \end{aligned}$$

□

Remarque : Notons \mathcal{L}^0 l'ensemble des variables aléatoires sur $(\Omega, \mathcal{F}, \mathbb{P})$ et $L^0 = \mathcal{L}^0 / \sim$.

$$d(X, Y) = \inf\{c > 0, \mathbb{P}(|X - Y| > c) \leq c\}.$$

d est une distance sur L^0 : la convergence pour la distance d est la convergence en probabilité.

6.2 Convergence étroite et convergence en loi

6.2.1 Convergence étroite

Soit (μ_n) une suite de mesures de probabilité sur \mathbb{R}^d . Soit μ une probabilité sur \mathbb{R}^d . On note \mathcal{C}_b l'ensemble des fonctions continues bornées $f : \mathbb{R}^d \rightarrow \mathbb{R}$ et \mathcal{C}_c l'ensemble des fonctions continues à support compact $f : \mathbb{R}^d \rightarrow \mathbb{R}$.

Définition 6.16

La suite (μ_n) converge étroitement vers μ si

$$\forall f \in \mathcal{C}_b, \quad \int_{\mathbb{R}^d} f(x) \mu_n(dx) \xrightarrow[n \rightarrow +\infty]{} \int_{\mathbb{R}^d} f(x) \mu(dx).$$

Remarque : La continuité de f est essentielle. Par conséquent, on n'a pas forcément $\mu_n(B) \xrightarrow{n \rightarrow +\infty} \mu(B)$ pour $B \in \mathcal{B}(\mathbb{R}^d)$.

Exemple : $\mu = \delta_{\frac{1}{n}}$.

$$\int f d\mu_n = f\left(\frac{1}{n}\right) \xrightarrow{n \rightarrow +\infty} f(0) = \int f d\delta_0.$$

$B = \{0\}$ $\delta_n(B) = 0$ mais $\delta_0(B) = 1$.

Proposition 6.17

Soit $H \subset \mathcal{C}_b$ tel que $\mathcal{C}_c \subset \overline{H}^{\|\cdot\|_\infty}$. Alors une suite de mesures de probabilité (μ_n) converge étroitement vers μ si et seulement si

$$\forall f \in H, \quad \int f d\mu_n \xrightarrow{n \rightarrow +\infty} \int f d\mu.$$

▷ Si $\mu_n \rightarrow \mu$ alors $\int f d\mu_n \rightarrow \int f d\mu$ pour tout $f \in H$ car f est bornée.

(i) Si $H = \mathcal{C}_c$, on utilise un argument de troncature. Soit $\theta_k : \mathbb{R}^+ \rightarrow [0, 1]$ telle que $\theta_k \equiv 1$ sur $[0, k]$, θ_k linéaire sur $[k, 2k]$ et $\theta_k \equiv 0$ sur $[2k, +\infty[$. Soit $f \in \mathcal{C}_b$.

$$f(x) = f(x)\theta_k(|x|) + f(x)(1 - \theta_k(|x|))$$

donc

$$\int f d\mu_n = \int f\theta_k d\mu_n + \int f(1 - \theta_k) d\mu_n$$

et

$$\int f d\mu = \int f\theta_k d\mu + \int f(1 - \theta_k) d\mu.$$

$$\begin{aligned} \left| \int f d\mu_n - \int f d\mu \right| &\leq \left| \int f\theta_k d\mu_n - \int f\theta_k d\mu \right| + \left| \int f(1 - \theta_k) d\mu_n \right| + \left| \int f(1 - \theta_k) d\mu \right| \\ &\leq \left| \int f\theta_k d\mu_n - \int f\theta_k d\mu \right| + \|f\|_\infty \left(1 - \int \theta_k d\mu_n \right) + \|f\|_\infty \left(1 - \int \theta_k d\mu \right). \end{aligned}$$

donc, comme $\theta_k, f\theta_k \in \mathcal{C}_c$,

$$\limsup_n \left| \int f d\mu_n - \int f d\mu \right| \leq 0 + 2\|f\|_\infty (1 - \int \theta_k d\mu).$$

Par ailleurs, $\theta_k(x) \xrightarrow{k \rightarrow +\infty} 1$ et $|\theta_k(x)| \leq 1$ donc par le théorème de convergence dominée $\int \theta_k d\mu \xrightarrow{k \rightarrow +\infty} 1$ donc

$$\forall f \in \mathcal{C}_b, \quad \left| \int f d\mu_n - \int f d\mu \right| \xrightarrow{n \rightarrow +\infty} 0$$

donc $\mu_n \rightarrow \mu$ étroitement.

(ii) Cas général. Soit $f \in \mathcal{C}_c$. Soit $\varepsilon > 0$. Comme $\mathcal{C}_c \in \overline{H}$, il existe $h_\varepsilon \in H$ tel que $\|f - h_\varepsilon\| < \varepsilon$. Alors, en écrivant $f = h_\varepsilon + (f - h_\varepsilon)$, on a :

$$\left| \int f d\mu_n - \int f d\mu \right| \leq \left| \int h_\varepsilon d\mu_n - \int h_\varepsilon d\mu \right| + 2\varepsilon$$

Donc pour tout $f \in \mathcal{C}_c$ $\int f d\mu_n \rightarrow \int f d\mu$. Donc $\mu_n \rightarrow \mu$ étroitement. \square

cours 15 mars

Lemme 6.18 (*Slutsky*)

Si $X_n \xrightarrow[n \rightarrow +\infty]{\mathcal{L}} X$ et $Y_n \xrightarrow[n \rightarrow +\infty]{\mathbb{P}} c$ où c est une constante alors $(X_n, Y_n) \xrightarrow[n \rightarrow +\infty]{\mathcal{L}} (X, c)$.

Application : Si $X_n \xrightarrow[n \rightarrow +\infty]{\mathcal{L}} X$ et $X_n - Y_n \xrightarrow[n \rightarrow +\infty]{\mathbb{P}} 0$ alors $Y_n \xrightarrow[n \rightarrow +\infty]{\mathcal{L}} X$. En effet, $Y_n = X_n + (Y_n - X_n)$ comme on a $(X_n, Y_n - X_n) \xrightarrow[n \rightarrow +\infty]{\mathcal{L}} (X, 0)$, par le lemme de Slutsky on a bien $Y_n \xrightarrow[n \rightarrow +\infty]{\mathcal{L}} X + 0 = X$.

▷ On a

$$\varphi_{(X,c)}(s, t) = \mathbb{E}[e^{i(sX+tc)}] = e^{itc} \varphi_X(s).$$

Donc

$$\begin{aligned} |\varphi_{(X_n, Y_n)}(s, t) - \varphi_{(X, c)}(s, t)| &= |\mathbb{E}[e^{isX_n} e^{itY_n}] - e^{itc} \mathbb{E}[e^{isX_n}] - e^{itc} \mathbb{E}[e^{isX_n}] + e^{itc} \mathbb{E}[e^{isX}]| \\ &\leq |\mathbb{E}[e^{isX_n} (e^{itY_n} - e^{itc})]| + |e^{itc} (\mathbb{E}[e^{isX_n}] - \mathbb{E}[e^{isX}])| \\ &\leq \underbrace{\mathbb{E}[|e^{itY_n} - e^{itc}|]}_{\leq \varepsilon |t| + 2\mathbb{P}(|Y_n - c| > \varepsilon) \quad \forall \varepsilon \text{ cf preuve prec.}} + \underbrace{|\varphi_{X_n}(s) - \varphi_X(s)|}_{\xrightarrow[n \rightarrow +\infty]{\mathcal{L}} 0 \text{ car } X_n \xrightarrow{\mathcal{L}} X}. \end{aligned}$$

On en déduit que

$$\forall s, t \in \mathbb{R}, \quad \varphi_{(X_n, Y_n)}(s, t) \xrightarrow[n \rightarrow +\infty]{} \varphi_{(X, c)}(s, t).$$

Donc par le théorème de Paul-Lévy

$$(X_n, Y_n) \xrightarrow[n \rightarrow +\infty]{\mathcal{L}} (X, c).$$

\square

Exemple : Soit (X_n) une suite de variables aléatoires telle que X_n suit la loi géométrique $\mathcal{G}(\frac{\lambda}{n})$ avec $\lambda > 0$. Convergence en loi de X_n de $n \rightarrow +\infty$? Pour $t > 0$,

$$\varphi_{X_n}(t) = \frac{\frac{\lambda}{n} e^{it}}{1 - (1 - \frac{\lambda}{n}) e^{it}} \xrightarrow[n \rightarrow +\infty]{} 0$$

mais $\varphi_{X_n}(0) = 1$ donc X_n ne converge pas en loi.

Regardons $Y_n = \frac{X_n}{n}$

$$\varphi_{Y_n}(t) = \mathbb{E}[e^{itY_n}] = \mathbb{E}[e^{i\frac{t}{n}X_n}] = \varphi_{X_n}\left(\frac{t}{n}\right) = \frac{\frac{\lambda}{n} e^{i\frac{t}{n}}}{1 - (1 - \frac{\lambda}{n}) e^{i\frac{t}{n}}} = \frac{\lambda e^{i\frac{t}{n}}}{n - (n - \lambda) e^{i\frac{t}{n}}} = \frac{\lambda e^{i\frac{t}{n}}}{n(1 - e^{i\frac{t}{n}}) + \lambda e^{i\frac{t}{n}}}$$

donc

$$\varphi_{Y_n}(t) \xrightarrow[n \rightarrow +\infty]{} \frac{\lambda}{\lambda - it}$$

(fonction caractéristique de la loi exponentielle $\mathcal{E}(\lambda)$) Ainsi,

$$Y_n = \frac{X_n}{n} \xrightarrow[n \rightarrow +\infty]{\mathcal{L}} \mathcal{E}(\lambda).$$

6.3 Conclusion

$$\begin{array}{ccccc}
 & & \text{cv dans } L^1 & \Leftarrow & \text{cv dans } L^p, p \geq 1 \Leftarrow \text{cv dans } L^\infty \\
 & & \Downarrow & & \\
 \text{cv ps} & \Rightarrow & \text{cv en proba} & \Rightarrow & \text{cv en loi} \\
 & \Leftarrow & & \Leftarrow & \\
 & \exists \text{ss suite qui cv ps} & & \text{si limite=cste} &
 \end{array}$$

Si on a convergence en probabilité en uniforme intégrabilité *ie.*

$$\lim_{n \rightarrow +\infty} \sup_{a > 0} \mathbb{E}[|X_n| \mathbf{1}_{|X_n| > a}] = 0$$

alors on a convergence dans L^1 .

Chapitre 7

Théorèmes limites

On va considérer une suite $(X_n)_{n \geq 1}$ de variables aléatoires indépendantes identiquement distribuées (de même loi).

7.1 Loi des grands nombres

7.1.1 Version faible de la loi des grands nombres

Théorème 7.1

Soit (X_n) une suite de variables aléatoires indépendantes identiquement distribuées ayant un moment d'ordre 1 fini : $\mathbb{E}[|X_1|] < +\infty$. Alors,

$$\frac{X_1 + \cdots + X_n}{n} \xrightarrow[n \rightarrow +\infty]{\mathbb{P}} \mathbb{E}[X_1].$$

Application : Si les variables aléatoires X_n suivent la loi $\mathcal{B}(p)$, alors $\frac{X_1 + \cdots + X_n}{n}$ représente le nombre moyen de succès sur n expériences. D'après la loi des grands nombres, on a

$$\frac{X_1 + \cdots + X_n}{n} \xrightarrow[n \rightarrow +\infty]{\mathbb{P}} p.$$

▷ (i) Preuve dans le cas L^2 . On suppose les X_n dans L^2 . On note $m = \mathbb{E}[X_1]$ et $\sigma^2 = \text{Var}(X_1)$. On veut montrer que

$$\forall \varepsilon > 0, \quad \mathbb{P}(|M_n - m| > \varepsilon) \xrightarrow[n \rightarrow +\infty]{} 0$$

où $M_n = \frac{X_1 + \cdots + X_n}{n}$. Or

$$\mathbb{E}[M_n] = m$$

et, comme les variables sont indépendantes

$$\text{Var}(M_n) = \frac{1}{n^2} \sum_{i=1}^n \text{Var}(X_i) = \frac{\sigma^2}{n}.$$

Soit $\varepsilon > 0$. Par le théorème de Bienaymé-Tchebychev

$$\mathbb{P}(|M_n - m| > \varepsilon) \leq \frac{\text{Var}(M_n)}{\varepsilon^2} = \frac{\sigma^2}{n\varepsilon^2} \xrightarrow[n \rightarrow +\infty]{} 0$$

donc $M_n \xrightarrow[n \rightarrow +\infty]{\mathbb{P}} m$.

(ii) Preuve dans le cas L^1 . Il suffit de montrer que $M_n \xrightarrow[n \rightarrow +\infty]{\mathcal{L}} m$. On étudie la fonction caractéristique de M_n .

$$M_n = \frac{X_1 + \cdots + X_n}{n} \xrightarrow[n \rightarrow +\infty]{} m \iff \frac{(X_1 - m) + \cdots + (X_n - m)}{n} \xrightarrow[n \rightarrow +\infty]{} 0$$

donc on peut supposer que les variables X_i sont centrées. Notre but est alors de montrer que

$$\varphi_{M_n}(t) \xrightarrow[n \rightarrow +\infty]{} 1.$$

Comme les variables sont indépendantes,

$$\varphi_{M_n}(t) = \prod_{k=1}^n \mathbb{E} \left[e^{i \frac{X_k}{n} t} \right] = \prod_{k=1}^n \varphi_{X_1} \left(\frac{t}{n} \right) = \varphi_{X_1} \left(\frac{t}{n} \right)^n.$$

Lemme 7.2

Pour tout $x \in \mathbb{R}$,

$$\left| e^{ix} - \sum_{k=0}^p \frac{(ix)^k}{k!} \right| \leq \min \left(\frac{|x|^{p+1}}{(p+1)!}, \frac{2|x|^p}{p!} \right).$$

On en déduit que

$$\left| \mathbb{E} [e^{itX}] - \sum_{k=0}^p \frac{i^k t^k \mathbb{E}[X^k]}{k!} \right| \leq \mathbb{E} \left[\min \left(\frac{|t|^{p+1} |X|^{p+1}}{(p+1)!}, \frac{2|t|^p |X|^p}{p!} \right) \right].$$

Lemme 7.3

$\forall a_i, b_i \in \mathbb{C}$ avec $\forall i, |a_i| \leq 1$ et $|b_i| \leq 1$

$$\left| \prod_{i=1}^n a_i - \prod_{i=1}^n b_i \right| \leq \sum_{i=1}^n |a_i - b_i|$$

▷ (premier lemme) – En utilisant le développement de Taylor avec reste intégral,

$$e^{ix} - \sum_{k=0}^p \frac{(ix)^k}{k!} = \frac{i^{p+1}}{p!} \int_0^x (x-s)^p e^{is} ds$$

donc

$$\left| e^{ix} - \sum_{k=0}^p \frac{(ix)^k}{k!} \right| \leq \frac{1}{p!} \left| \int_0^x (x-s)^p ds \right| = \frac{|x|^{p+1}}{(p+1)!}.$$

– De même,

$$e^{ix} - \sum_{k=0}^p \frac{(ix)^k}{k!} = \frac{i^p}{(p-1)!} \int_0^x (x-s)^{p-1} e^{is} ds - \frac{i^p x^p}{p!}$$

donc

$$\left| e^{ix} - \sum_{k=0}^p \frac{(ix)^k}{k!} \right| \leq \frac{1}{(p-1)!} \left| \int_0^x (x-s) ds \right| + \frac{|x|^p}{p!} \leq \frac{2|x|^p}{p!}$$

□

▷ (second lemme) Preuve par récurrence.

- pour $n = 1$: trivial
- si c'est vrai au rang n

$$\prod_{i=1}^{n+1} a_i - \prod_{i=1}^{n+1} b_i = a_{n+1} \left(\prod_{i=1}^n a_i - \prod_{i=1}^n b_i \right) + \prod_{i=1}^n b_i (a_{n+1} - b_{n+1})$$

donc

$$\left| \prod_{i=1}^{n+1} a_i - \prod_{i=1}^{n+1} b_i \right| \leq \left| \prod_{i=1}^n a_i - \prod_{i=1}^n b_i \right| + |a_{n+1} - b_{n+1}|$$

et on conclut par hypothèse de récurrence.

□

On peut achever la preuve du théorème.

$$|\varphi_{M_n}(t) - 1| = \left| \varphi_X \left(\frac{t}{n} \right)^n - 1 \right| \leq \sum_{i=1}^n \left| \varphi_X \left(\frac{t}{n} \right) - 1 \right| = n \left| \varphi_X \left(\frac{t}{n} \right) - 1 \right|$$

Or, comme $\mathbb{E}[X] = 0$,

$$\begin{aligned} n \left| \varphi_X \left(\frac{t}{n} \right) - 1 \right| &= n \left| \mathbb{E} \left[e^{iX \frac{t}{n}} \right] - 1 \right| \\ &= n \left| \mathbb{E} \left[e^{iX \frac{t}{n}} \right] - 1 - \frac{it}{n} \mathbb{E}[X] \right| \\ &\leq n \mathbb{E} \left[\min \left(\frac{|t|^2 |X|^2}{2n^2}, \frac{2|t| |X|}{n} \right) \right] \\ &\leq \mathbb{E} \left[\min \left(\frac{|t|^2 |X|^2}{2n}, 2|t| |X| \right) \right] \end{aligned}$$

Par le théorème de convergence dominée, on a

$$n \left| \varphi_X \left(\frac{t}{n} \right) - 1 \right| \xrightarrow{n \rightarrow +\infty} 0$$

donc $\varphi_{M_n}(t) \xrightarrow{n \rightarrow +\infty} 1$. Ainsi $M_n \xrightarrow[n \rightarrow +\infty]{\mathcal{L}} 0$ et donc $M_n \xrightarrow[n \rightarrow +\infty]{\mathbb{P}} 0$.

□

7.1.2 Version forte de la loi des grands nombres

Théorème 7.4

Soit $(X_n)_{n \geq 1}$ une suite de variables aléatoires indépendantes identiquement distribuées dans

L^1 . Alors

$$\frac{X_1 + \cdots + X_n}{n} \xrightarrow[n \rightarrow +\infty]{p.s.} \mathbb{E}[X_1].$$